

INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO

ESCOM

Trabajo Terminal

Prototipo de Sistema de Detección y Apoyo para la Prevención de Enfermedades Neurodegenerativas

TT No. 2026-B141

Presentan

Rivera García Jonathan Ulises

Pardo Gómez Isaac

Meza Bravo Iván Marcelino

Directora

Dra. Palacios Solano Rocío



Ciudad de México — 2026





INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE COMPUTO



Documento Técnico

"Prototipo de Sistema de Detección y Apoyo para la Prevención de Enfermedades Neurodegenerativas"

Presentan

Rivera García Jonathan Ulises

Pardo Gómez Isaac

Meza Bravo Iván Marcelino

Directora:

Lic. Palacios Solano Rocío

Resumen:

Las enfermedades neurodegenerativas asociadas al deterioro cognitivo, como el deterioro cognitivo leve, la enfermedad de Alzheimer y la demencia vascular, representan uno de los principales desafíos de salud pública a nivel mundial. La Organización Mundial de la Salud estima que más de 55 millones de personas viven con algún tipo de demencia, cifra que se proyecta a triplicarse para 2050. En México, aproximadamente 1.3 millones de personas padecen algún tipo de demencia. El presente Trabajo Terminal propone el desarrollo de un prototipo de sistema inteligente que, mediante evaluación cognitiva digital basada en los dominios del MoCA, modelos de clasificación supervisada (regresión logística, SVM y Random Forest) y seguimiento longitudinal, permita estimar probabilísticamente el riesgo asociado a enfermedades neurodegenerativas, apoyando la detección temprana sin sustituir el diagnóstico clínico profesional.

Palabras clave: enfermedades neurodegenerativas, deterioro cognitivo leve, aprendizaje automático, MoCA, detección temprana, clasificación supervisada, seguimiento longitudinal.

[1] jriverag2100@alumno.ipn.mx

[2] ipardog@alumno.ipn.mx

[3] imezab@alumno.ipn.mx

Advertencia

"Este documento contiene información desarrollada por la Escuela Superior de Cómputo del Instituto Politécnico Nacional, a partir de datos y documentos con derecho de propiedad y, por lo tanto, su uso quedará restringido a las aplicaciones que explícitamente se convengan."

La aplicación no convenida exime a la escuela de su responsabilidad técnica y da lugar a las consecuencias legales que para tal efecto se determinen.

Información adicional sobre este reporte técnico podrá obtenerse en: La Subdirección Académica de la Escuela Superior de Cómputo del Instituto Politécnico Nacional, situada en Av. Juan de Dios Bátiz s/n — Teléfono: 57296000, extensión 52000.

ÍNDICE GENERAL

CAPITULO 1. INTRODUCCION 7
1.1 INTRODUCCION 7
1.2. PLANTAMIENTO DEL PROBLEMA 8
1.3. PROPUESTA DE SOLUCION 9
1.4. OBJETIVO GENERAL 10
1.5. OBJETIVOS ESPECIFICOS 10
1.6. JUSTIFICACION 11
1.7. METOLOGIA DE DESARROLLO 12
CAPITULO 2. ESTADO DEL ARTE 13
2.1 LUMOSITY 13
2.1.1 Caracteristicas 14
2.1.2 Ventajas 14
2.1.3 Desventajas 15
2.2 COGNIFIT 16
2.2.1 Características 16
2.2.2 Ventajas 17
2.2.3 Desventajas 17
2.3 PROYECTO DE GRUPO DE INVESTIGACION ACADEMICA 2004-1276 18
2.3.1 Características 18
2.3.3 Desventajas 19
2.4 PROTOTIPOS ACADÉMICOS DE APOYO COGNITIVO 20
2.4.1 Características 20
2.4.2 Ventajas 21
2.4.3 Desventajas 21
2.5 SISTEMAS DE INVESTIGACION BASADOS EN APRENDIZAJE AUTOMÁTICO PARA LA DETECCIÓN DE DETERIORO COGNITIVO 22
2.5.1 Principales Estudios y Resultados 22
2.5.2 Ventajas 23
2.5.3 Desventajas 23
2.6 Tabla Comparativa 24
CAPITULO 3. MARCO TEÓRICO 26
3.1 ENFERMEDADES NEURODEGENERATIVAS 26
3.1.1 Deterioro Cognitivo Leve (DCL) 26
3.1.2 Enfermedad de Alzheimer 26
3.1.3 Deterioro Cognitivo Vascular 27
3.2 PRUEBA MONTREAL COGNITIVE ASSESSMENT (MoCA) 27

3.2.1 Dominios Evaluados....27
3.2.2 Puntuacion y Puntos de Corte....28
3.3 MINERIA DE DATOS Y PREPROCESAMIENTO....28
3.3.1 Proceso KDD....28
3.3.2 Tecnicas de Preprocesamiento....29
3.3.3 Seleccion de Caracteristicas....29
3.4 APRENDIZAJE AUTOMATICO....30
3.4.1 Regresion Logistica....30
3.4.2 Maquinas de Soporte Vectorial (MVS)....30
3.4.3 Bosque Aleatorio (Random Forest)....31
3.4.4 Metricas de Evaluacion....32
3.4.5 Validacion Cruzada....32
3.5 SISTEMAS DE APOYO A LA DECISION CLINICA (CDSS)....32
3.5.2 Explicabilidad e Interpretabilidad (XAI)....33
3.6 APLICACIONES MOVILES EN SALUD (mHealth)....33
3.7 METODOLOGIA EN V....34
3.7.1 Fases del Modelo en V....34
3.7.2 Justificacion de la Metodologia para el Proyecto....34
3.8 ARQUITECTURA TECNOLOGICA DEL SISTEMA....34
3.9 HERRAMIENTAS PARA EL DESARROLLO MOVIL (FRONT-END)....35
3.9.1 React Native....35
3.10 HERRAMIENTAS PARA EL DESARROLLO DE SERVICIOS (BACK-END)....36
3.10.1 Python....36
3.10.2 FastAPI....36
3.10.3 Transferencia de Estado Representacional (REST)....36
3.11 BIBLIOTECAS PARA EL ANALISIS DE DATOS CLINICOS....37
3.11.1 NumPy....37
3.11.2 pandas....37
3.12 HERRAMIENTAS DE APRENDIZAJE AUTOMATICO....37
3.12.1 scikit-learn....37
3.12.2 imbalanced-learn y SMOTE....38
3.12.3 SHAP (Valores de Shapley para Explicaciones Aditivas)....38
3.13 HERRAMIENTAS DE VISUALIZACION Y REPORTES....38
3.13.1 Matplotlib y Seaborn....38
3.13.2 ReportLab....39
3.14 GESTION DE BASES DE DATOS Y PERSISTENCIA....39
3.14.1 PostgreSQL....39

3.14.2 SQLAlchemy y el Patron ORM 39
3.15 INFRAESTRUCTURA Y SERVICIOS EN LA NUBE 40
3.15.1 Azure App Service 40
3.15.2 Azure Database for PostgreSQL 40
3.15.3 Azure Blob Storage 41
3.16 SEGURIDAD Y AUTENTICACION 41
3.16.1 JWT (Tokens Web de JSON) 41
3.16.2 bcrypt 41
CAPÍTULO 4 ÁRBOL DE PROBLEMAS 42
4.1 *Problema Central* 42
4.2 Causas 42
4.3 Consecuencias 43
CAPITULO 5. ALCANCES Y LIMITACIONES 43
5.1. Alcances 43
5.2. Limitaciones 44
CAPITULO 6. ANÁLISIS 44
6.1. LEVANTAMIENTO DE REQUERIMIENTOS 44
6.1.2 Usuarios del sistema y roles 47
6.2 REQUERIMIENTOS FUNCIONALES 48
6.2.1 Módulo de Autenticación y Gestión de Acceso 48
6.2.2 Módulo de Perfil de Usuario 49
6.2.3 Módulo de Evaluación Cognitiva 50
6.2.4 Módulo del Motor Predictivo 52
6.2.5 Módulo de Seguimiento Longitudinal 53
6.2.6 Módulo de Estimulación Cognitiva 54
6.2.7 Módulo de Reportes 55
6.3 REQUERIMIENTOS NO FUNCIONALES 56
6.4. ANÁLISIS DE FACTIBILIDAD 59
6.4.1 Factibilidad operativa 59
6.4.2. Factibilidad tecnológica. 61
6.4.3. Factibilidad económica. 64
6.4.4. Factibilidad legal y ética 69
6.4.5. Factibilidad temporal 70
REFERENCIAS 72

CAPITULO 1. INTRODUCCION

1.1 INTRODUCCION

Las enfermedades neurodegenerativas asociadas al deterioro cognitivo, como el deterioro cognitivo leve (DCL), la enfermedad de Alzheimer y la demencia vascular, constituyen uno de los principales desafíos de salud pública a nivel mundial. De acuerdo con la Organización Mundial de la Salud (OMS), más de 55 millones de personas viven actualmente con algún tipo de demencia, y se estima que esta cifra podría triplicarse para el año 2050 debido al envejecimiento de la población [1]. En México, la magnitud del problema también es significativa, con aproximadamente 1.3 millones de personas afectadas, predominando la enfermedad de Alzheimer como la causa principal [2].

Estas enfermedades se caracterizan por un deterioro progresivo de diversas funciones cognitivas, como la memoria, la atención, el lenguaje y las funciones ejecutivas, lo que impacta de manera directa en la calidad de vida y la autonomía de los pacientes. Asimismo, la prevalencia de demencia en personas mayores de 60 años en México se estima en un 7.9 %, con una mayor incidencia en mujeres y en zonas rurales, lo que evidencia la necesidad de fortalecer estrategias de atención y diagnóstico oportuno [3].

En este contexto, la detección temprana del deterioro cognitivo se vuelve un elemento clave para mejorar el pronóstico de los pacientes y permitir intervenciones que contribuyan a ralentizar la progresión de la enfermedad. Herramientas como la Evaluación Cognitiva de Montreal (MoCA) han demostrado ser eficaces para la identificación de alteraciones cognitivas en etapas iniciales; sin embargo, su implementación suele limitarse a entornos clínicos tradicionales, lo que reduce su alcance y continuidad en el seguimiento de los pacientes [4].

Ante esta problemática, resulta necesario explorar el uso de tecnologías digitales que faciliten la evaluación cognitiva, el almacenamiento de información y el análisis de datos, permitiendo así una atención más eficiente, accesible y oportuna. En particular, el uso de aplicaciones web y técnicas de análisis de datos representa una oportunidad para mejorar los procesos de detección y seguimiento del deterioro cognitivo, contribuyendo al desarrollo de soluciones innovadoras en el ámbito de la salud.

1.2. PLANTAMIENTO DEL PROBLEMA

El deterioro cognitivo asociado a enfermedades neurodegenerativas, como el deterioro cognitivo leve (DCL), la enfermedad de Alzheimer y la demencia vascular, representa un problema creciente de salud pública debido a su alta prevalencia y al impacto significativo en la calidad de vida de los pacientes. A nivel mundial, estas condiciones afectan a millones de personas y su incidencia aumenta progresivamente con el envejecimiento de la población [1]. En México, el incremento de casos, junto con limitaciones en la infraestructura de atención médica, agrava la situación y dificulta su abordaje oportuno [2].

Uno de los principales retos en el manejo de estas enfermedades es la **detección temprana del deterioro cognitivo**, ya que diversos estudios han demostrado que los síntomas iniciales suelen ser sutiles y frecuentemente pasan desapercibidos tanto por los pacientes como por los profesionales de la salud [5]. Esto provoca que una gran proporción de los diagnósticos se realice en etapas avanzadas, reduciendo significativamente la efectividad de las intervenciones disponibles y limitando las posibilidades de ralentizar la progresión del deterioro [6].

En este contexto, herramientas de evaluación cognitiva como el Montreal Cognitive Assessment (MoCA) (Evaluación Cognitiva de Montreal) han demostrado ser eficaces para la identificación de alteraciones cognitivas en fases tempranas [4]. No obstante, su aplicación se encuentra mayormente restringida a entornos clínicos presenciales, y en muchos casos carece de mecanismos automatizados para el almacenamiento, análisis y seguimiento continuo de los resultados, lo que dificulta la identificación de patrones evolutivos en los pacientes.
Adicionalmente, investigaciones recientes destacan el potencial de las tecnologías digitales y técnicas de análisis de datos, como el aprendizaje automático, para mejorar los procesos de detección temprana y monitoreo del deterioro cognitivo [7]. Sin embargo, en la práctica, muchas de las soluciones disponibles se enfocan únicamente en actividades de estimulación cognitiva o evaluaciones aisladas, sin integrar modelos analíticos que permitan generar información útil para la toma de decisiones clínicas.

En consecuencia, existe la necesidad de desarrollar una solución tecnológica que facilite la evaluación cognitiva, automatice el registro de resultados y permita el análisis estructurado de la información mediante técnicas de minería de datos. La implementación de una aplicación web orientada a este propósito podría contribuir a mejorar la detección temprana y el seguimiento del deterioro cognitivo, favoreciendo una atención más oportuna y eficiente.

1.3. PROPUESTA DE SOLUCION

Se propone el desarrollo de un **prototipo de sistema inteligente orientado a la detección temprana y apoyo en la prevención del deterioro cognitivo**, mediante la integración de herramientas digitales de evaluación, análisis de datos y estimulación cognitiva personalizada.

La solución consiste en una **aplicación móvil** que digitaliza la prueba Evaluacion Cognitiva de Montreal (MoCA), permitiendo la captura estructurada de los resultados correspondientes a los distintos dominios cognitivos evaluados, tales como memoria, atención, lenguaje, funciones ejecutivas y orientación. Esta información será almacenada en una base de datos centralizada, junto con variables sociodemográficas relevantes del usuario (edad, sexo, nivel educativo, enfermedades).

A partir de estos datos, el sistema implementará un **módulo de análisis basado en técnicas de minería de datos y aprendizaje automático**, utilizando modelos de clasificación supervisada como regresión logística, máquinas de soporte vectorial (MSV) y Random Forest. Estos modelos serán entrenados con datos previamente etiquetados, con el objetivo de **estimar probabilísticamente el nivel de riesgo** de presentar deterioro cognitivo leve, enfermedad de Alzheimer o deterioro cognitivo vascular.

Adicionalmente, el sistema incorporará un **módulo de seguimiento longitudinal**, que permitirá registrar la evolución de los puntajes cognitivos del usuario a lo largo del tiempo. Esto facilitará la identificación de patrones de cambio y tendencias asociadas al deterioro cognitivo, generando reportes visuales e interpretables tanto para el usuario como para posibles profesionales de la salud.

Como complemento, la solución incluirá un **módulo de estimulación cognitiva personalizada**, el cual recomendará actividades interactivas (ejercicios de memoria, atención, razonamiento, entre otros) basadas en el desempeño del usuario en los distintos dominios evaluados. Estas actividades estarán diseñadas para fortalecer áreas cognitivas específicas y contribuir a la prevención del deterioro seguiendo evaluando patrones y comportamientos del paciente.

1.4. OBJETIVO GENERAL

Desarrollar un prototipo de sistema inteligente que integre evaluación cognitiva digital basada en los dominios del MoCA, modelos predictivos de clasificación supervisada entrenada con datos clínicos etiquetados y un módulo de seguimiento longitudinal, con el fin de estimar probabilísticamente el riesgo asociado a enfermedades neurodegenerativas y apoyar la detección temprana sin sustituir el diagnóstico clínico profesional.

1.5. OBJETIVOS ESPECIFICOS

- Analizar y preparar una base de datos clínica que incluya variables relevantes para la detección de deterioro cognitivo.
- Desarrollar y evaluar modelos de clasificación supervisada para identificar patrones asociados a deterioro cognitivo leve, enfermedad de Alzheimer y deterioro cognitivo vascular.
- Diseñar e implementar un módulo digital de evaluación cognitiva basado en los dominios del MoCA.
- Desarrollar un sistema que permita estimar el nivel de riesgo cognitivo del usuario y generar reportes interpretables.
- Implementar un mecanismo de seguimiento que permita analizar la evolución del desempeño cognitivo del usuario en el tiempo.
- Integrar actividades de estimulación cognitiva personalizadas de acuerdo con el desempeño del usuario.
- Validar el funcionamiento general del sistema mediante pruebas que permitan evaluar su desempeño.

1.6. JUSTIFICACION

Las enfermedades neurodegenerativas asociadas al deterioro cognitivo representan uno de los principales desafíos de salud pública a nivel mundial y nacional. La Organización Mundial de la Salud estima que más de 55 millones de personas viven actualmente con algún tipo de demencia, cifra que se proyecta a triplicarse para el año 2050 como consecuencia del envejecimiento poblacional [8] [9].

En México, aproximadamente 1.3 millones de personas padecen algún tipo de demencia, de las cuales entre el 60 y el 70 % corresponden a la enfermedad de Alzheimer, con una proyección de 3.5 millones de casos para 2050 [9], [10].
Uno de los problemas centrales en el abordaje clínico de estas enfermedades radica en la detección tardía de los primeros signos de deterioro cognitivo. Datos del Instituto Nacional de Neurología y Neurocirugía de México indican que alrededor del 70 % de los pacientes atendidos por demencia llegan en etapas avanzadas de la enfermedad [9] [10], lo que limita significativamente las posibilidades de intervención oportuna. Los síntomas iniciales del deterioro cognitivo leve suelen confundirse con cambios propios del envejecimiento normal o del estrés, retrasando la evaluación especializada y, con ello, la aplicación de estrategias preventivas que podrían ralentizar la progresión de la enfermedad [3], [11] [12].

Herramientas clínicas como la prueba Montreal Cognitive Assessment (MoCA) permiten identificar alteraciones cognitivas en etapas tempranas con una sensibilidad estimada del 90 % [12]; sin embargo, su aplicación se encuentra limitada a entornos clínicos presenciales, con registro manual de resultados y sin integración a sistemas automatizados que faciliten el análisis longitudinal o la estimación probabilística de riesgo [13]. Esta situación genera una brecha entre la evaluación clínica tradicional y el aprovechamiento de técnicas de aprendizaje automático para el análisis estructurado de información cognitiva.

En este contexto, el presente Trabajo Terminal se justifica por las siguientes razones. En primer lugar, existe una necesidad concreta y documentada de herramientas digitales accesibles que integren evaluación cognitiva estandarizada, modelos predictivos y seguimiento longitudinal en un solo sistema, algo que las soluciones existentes no ofrecen de forma integrada ni con vínculo a instrumentos clínicos validados [14], [15] [16].

En segundo lugar, los avances recientes en aprendizaje automático han demostrado que modelos como Random Forest y SVM alcanzan precisiones superiores al 90 % en la clasificación de datos cognitivos y clínicos [16], [17], lo que respalda técnicamente la viabilidad del enfoque propuesto. En tercer lugar, la digitalización del proceso de evaluación cognitiva y la automatización del análisis de resultados amplían el alcance del instrumento MoCA más allá del entorno clínico, haciéndolo accesible como herramienta de apoyo para profesionales de salud de primer contacto, familiares y cuidadores [12],

1.7. METOLOGIA DE DESARROLLO

El presente proyecto se desarrolla bajo la metodología en V (V-Model), modelo de proceso de software que extiende el esquema en cascada incorporando de forma explícita las actividades de verificación y validación correspondientes a cada fase de desarrollo [15]. Esta metodología fue seleccionada por ser adecuada a las características del proyecto: los requerimientos del sistema están bien definidos desde el inicio a partir del análisis clínico y del instrumento MoCA [13]; la naturaleza del prototipo demanda una validación rigurosa y sistemática de cada componente, especialmente del modelo de aprendizaje automático, antes de la integración total del sistema; y el periodo acotado de dos semestres favorece una planificación secuencial y predecible con entregables verificables en cada fase.

El desarrollo se estructura en dos etapas principales correspondientes a TT1 y TT2, organizadas conforme a la correspondencia entre fases de diseño y sus respectivas etapas de validación.

Durante la primera etapa (TT1, febrero–junio 2026) se llevan a cabo las fases de análisis, diseño y preparación del componente analítico. Se inicia con el análisis y definición del problema, seguido del estudio de las enfermedades neurodegenerativas y el levantamiento de requerimientos del sistema. Con base en estos requerimientos, se procede al diseño de la interfaz de usuario conforme a los principios de usabilidad establecidos para aplicaciones mHealth orientadas a población adulta mayor [18], la arquitectura del sistema, el modelo de base de datos y los módulos del sistema. Paralelamente, se realiza la recolección y preparación de la base de datos clínica, que incluye diagnóstico confirmado, edad, escolaridad y puntajes por dominio del MoCA [13], [14], [15]. Esta etapa concluye con la evaluación de TT1.

Durante la segunda etapa (TT2, agosto–diciembre 2026) se desarrollan las fases de implementación y validación. Se aplican técnicas de minería de datos sobre la base preparada, incluyendo tratamiento de valores faltantes, normalización, codificación de variables categóricas, balanceo de clases mediante SMOTE y selección de características [16]. Posteriormente se implementan y evalúan los modelos de clasificación supervisada —regresión logística, máquinas de soporte vectorial y Random Forest— mediante validación cruzada de k pliegues, con métricas de exactitud, sensibilidad, especificidad, F1-Score y AUC-ROC [16] [17], [18]. Con el modelo seleccionado se procede a la codificación de la aplicación móvil, integrando los módulos de evaluación cognitiva, estimación de riesgo, seguimiento longitudinal y estimulación cognitiva personalizada [13], [14]. La etapa de validación comprende pruebas unitarias, de integración, de sistema y de aceptación, conforme a la estructura simétrica del modelo en V [15].

La calidad del proceso y la documentación sistemática se respaldan mediante los principios del estándar ISO 9001, aplicados a la planificación, control de avances y trazabilidad entre requerimientos, diseño e implementación [18].

CAPITULO 2. ESTADO DEL ARTE

El presente capítulo expone un análisis crítico de las principales herramientas, plataformas y enfoques de investigación relacionados con la evaluación cognitiva digital, el entrenamiento cerebral y la detección temprana de deterioro cognitivo mediante inteligencia artificial. El objetivo de este análisis es identificar las características, ventajas y limitaciones de cada solución existente, con el fin de fundamentar la pertinencia y originalidad de la propuesta del presente Trabajo Terminal 2026-B141.

Las soluciones analizadas se organizan en cinco categorías: [1] plataformas comerciales de entrenamiento cognitivo orientadas al público general, [2] un proyecto académico previo desarrollado en el Instituto Politécnico Nacional (IPN), [3] prototipos universitarios de apoyo cognitivo, [4] sistemas de investigación basados en aprendizaje automático para la clasificación de deterioro cognitivo, y [5] una tabla comparativa final que sintetiza los hallazgos del capítulo.

2.1 LUMOSITY

Lumosity es una plataforma de entrenamiento cerebral desarrollada por Lumos Labs Inc. y lanzada al mercado en 2007. Está orientada al público general y ofrece una colección de minijuegos diseñados para ejercitar funciones cognitivas como la memoria, la atención, la velocidad de procesamiento y la flexibilidad cognitiva [1]. Su modelo de negocio se basa en la suscripción mensual, con acceso disponible desde dispositivos móviles (sistemas operativos iOS y Android) y desde navegadores web.

La plataforma genera para cada usuario un índice de desempeño propio, denominado Índice de Desempeño Lumosity, que refleja el rendimiento agregado en los distintos minijuegos practicados. Este índice permite al usuario observar su progreso a lo largo del tiempo de forma visual e intuitiva. Sin embargo, dicho índice no está vinculado a ningún instrumento de evaluación cognitiva clínicamente validado, ni permite estimar el riesgo asociado a enfermedades neurodegenerativas.

2.1.1 Caracteristicas

En la tabla 2.1 se presentan las características principales de Lumosity como plataforma de entrenamiento cognitivo.

Aspecto	Descripción
Desarrollador	Lumos Labs Inc.
Plataforma	iOS, Andriod, Web
Dominios evaluados	Memoria, atención, velocidad de procesamiento, flexibilidad cognitiva
Base clínica	No vinculada a instrumento estandarizado
Modelos predictivos	No incorpora
Seguimiento longitudinal	Parcial (métricas de desempeño propias)
Costo	Suscripción desde $120MXN/mes

Tabla 2.1. Características principales de Lumosity [1].

La interfaz de Lumosity está diseñada con principios de gamificación, lo que favorece la adherencia del usuario a las sesiones diarias de entrenamiento. Cada sesión presenta tres o más actividades seleccionadas automáticamente en función del perfil del usuario. Las categorías de entrenamiento disponibles incluyen memoria, atención, velocidad de procesamiento, flexibilidad cognitiva y resolución de problemas.

2.1.2 Ventajas

- Interfaz intuitiva y atractiva, con alta accesibilidad para usuarios no técnicos y adultos mayores.
- Amplia variedad de actividades que cubren múltiples dominios cognitivos en sesiones cortas de entrenamiento.
- Disponible en múltiples idiomas y plataformas, lo que facilita su adopción en distintos contextos geográficos y culturales.
- Registro del progreso del usuario a lo largo del tiempo con visualización gráfica del Índice de Desempeño Lumosity.
- Amplia base de usuarios a nivel mundial, lo que ha permitido a la empresa generar datos de investigación a gran escala.

2.1.3 Desventajas

- No está vinculada a instrumentos de evaluación cognitiva clínicamente validados, como el MoCA o la Evaluación Cognitiva de Montreal.
- No genera estimaciones de riesgo asociadas a enfermedades neurodegenerativas como el Deterioro Cognitivo Leve (DCL), la enfermedad de Alzheimer o el deterioro cognitivo vascular.
- No contempla seguimiento longitudinal con análisis clínico estructurado ni generación de reportes para profesionales de la salud.
- Sus beneficios cognitivos a largo plazo han sido cuestionados en la literatura científica; la Comisión Federal de Comercio de los Estados Unidos sancionó a Lumos Labs en 2016 por publicidad engañosa respecto a sus afirmaciones de mejora cognitiva y prevención de demencia.
- El acceso completo a sus funcionalidades requiere una suscripción de pago mensual, lo que limita su disponibilidad para poblaciones de menores recursos.

2.2 COGNIFIT

CogniFit es una plataforma de evaluación y entrenamiento cognitivo desarrollada con base en evidencia científica. Fue fundada en el año 2000 y está orientada tanto al público general como a profesionales de la salud e investigadores [2]. A diferencia de Lumosity, CogniFit incorpora baterías de evaluación cognitiva adaptativas diseñadas para medir el nivel de desempeño del usuario en distintas habilidades mentales, y genera programas de entrenamiento personalizados a partir de los resultados obtenidos.

La plataforma cuenta con una versión clínica denominada CogniFit para Profesionales de la Salud, que permite a médicos, psicólogos y neuropsicólogos administrar evaluaciones a sus pacientes y acceder a reportes detallados de desempeño. Esta versión incluye herramientas de seguimiento del progreso del paciente a lo largo del tiempo, aunque sin integración a modelos de clasificación supervisada ni estimación probabilística de riesgo neurodegenerativo.

2.2.1 Características

En la Tabla 2.2 se presentan las características principales de CogniFit como plataforma de evaluación y entrenamiento cognitivo.

Aspecto	Descripción
Desarrollador	CogniFit Inc.
Plataforma	iOS, Andriod, Web
Dominios evaluados	Memoria, atención, funciones ejecutivas, coordinación y planificación.
Base clínica	Basada en evidencia cientifica; no usa el MoCA como instrumento base
Modelos predictivos	No incorpora modelos de clasificación supervisada
Seguimiento longitudinal	Parcial; sin analísis predictivo integrado

Tabla 2.2. Características principales de CogniFit [2].

CogniFit evalúa más de 20 habilidades cognitivas organizadas en dominios como memoria, atención, coordinación, percepción y razonamiento. Sus evaluaciones utilizan tareas cognitivas estandarizadas cuya validez ha sido respaldada en publicaciones científicas indexadas. La plataforma genera un perfil cognitivo visual del usuario que facilita la interpretación de los resultados.

2.2.2 Ventajas

- Basada en evidencia científica con validación en distintas poblaciones, incluyendo adultos mayores y pacientes con diagnósticos neurológicos.
- Las evaluaciones cognitivas están estructuradas y pueden personalizarse según el perfil y los objetivos del usuario o del profesional de la salud.
- La versión clínica permite la generación de reportes detallados de desempeño cognitivo orientados al profesional de la salud.
- Disponible en múltiples idiomas y plataformas, con interfaz adaptada para distintos grupos de edad.
- Cuenta con un catálogo amplio de más de 40 actividades de entrenamiento organizadas por dominio cognitivo.

2.2.3 Desventajas

- No utiliza el MoCA como instrumento base de evaluación, por lo que sus resultados no son directamente comparables con los criterios clínicos de cribado de DCL establecidos internacionalmente.
- No incorpora modelos de clasificación supervisada para la estimación probabilística de riesgo de deterioro neurodegenerativo a partir de datos clínicos etiquetados.
- El acceso completo a sus funcionalidades requiere una suscripción de pago mensual, con planes desde $200 MXN/mes para usuarios individuales y tarifas superiores para profesionales de la salud.
- No contempla seguimiento longitudinal integrado con análisis predictivo basado en aprendizaje automático.
- El alto costo de la suscripción limita su adopción como herramienta de apoyo en entornos de salud pública con recursos limitados.

2.3 PROYECTO DE GRUPO DE INVESTIGACION ACADEMICA 2004-1276

El Proyecto de Grupo de Investigación Académica (CGPI por sus siglas en inglés, Comisión de Grupos de Investigación del IPN) con número de registro 2004-1276 es una iniciativa académica desarrollada en el Instituto Politécnico Nacional, centrada en el diseño e implementación de actividades interactivas de estimulación cognitiva [8]. Representa un antecedente institucional directo en el abordaje de la estimulación de funciones mentales en el contexto del IPN y constituye una referencia metodológica para el presente Trabajo Terminal.

El proyecto se enfocó en el diseño pedagógico de actividades cognitivas estructuradas, con resultados relevantes en términos de la conceptualización de la estimulación cognitiva como herramienta de apoyo. Sin embargo, su alcance tecnológico fue limitado, dado que no incorporó técnicas de inteligencia artificial ni mecanismos de escalabilidad para su despliegue como aplicación móvil o plataforma web accesible.

2.3.1 Características

En la Tabla 2.3 se presentan las características principales del Proyecto de Grupo de Investigación Académica 2004-1276.

Aspecto	Descripción
Desarrollador	Instituto Politécnico Nacional
Plataforma	Aplicación de escritorio académica
Enfoque	Estimulación cognitiva mediante actividades interactivas
Inteligencia artificial	No incorpora
Escalabilidad	Limitada; sin despliegue como aplicación móvil
Costo	No comercial

Tabla 2.3. Características principales del Proyecto de Grupo de Investigación Académica 2004-1276 [8].

El proyecto se desarrolló en un contexto académico controlado, con actividades diseñadas para estimular funciones cognitivas específicas como la memoria, la atención y la orientación. Los resultados obtenidos sirvieron como base para publicaciones académicas en el ámbito de la estimulación cognitiva, aunque sin derivar en un producto tecnológico escalable ni en la incorporación de modelos analíticos avanzados

2.3.2 Ventajas

- Antecedente institucional relevante desarrollado en el contexto del IPN, con conocimiento del entorno académico y de las necesidades de la población objetivo.
- Enfoque centrado en la estimulación cognitiva con base en actividades diseñadas por especialistas en el área.
- Acceso no comercial, lo que garantiza la disponibilidad sin barreras económicas para los usuarios.
- Aporta referencias metodológicas y conceptuales para el diseño de actividades de estimulación en el contexto del presente Trabajo Terminal

2.3.3 Desventajas

- No incorpora técnicas de inteligencia artificial ni modelos de clasificación supervisada para la estimación de riesgo cognitivo.
- Carece de escalabilidad tecnológica para su despliegue como aplicación móvil accesible a usuarios fuera del entorno académico.
- No contempla evaluación cognitiva basada en instrumentos clínicos validados como el MoCA.
- Sin seguimiento longitudinal ni generación de reportes de riesgo orientados al profesional de la salud.
- El desarrollo del proyecto no derivó en un producto tecnológico funcional disponible para su uso en entornos clínicos reales.

2.4 PROTOTIPOS ACADÉMICOS DE APOYO COGNITIVO

En los últimos años, diversos equipos de estudiantes universitarios de México y Latinoamérica han desarrollado prototipos de sistemas de apoyo cognitivo como proyectos de titulación o trabajos de investigación. Estos proyectos exploran el uso de tecnologías digitales —principalmente aplicaciones móviles y plataformas web— para el diseño de actividades interactivas orientadas a la estimulación y evaluación de funciones cognitivas básicas.

Si bien estos prototipos demuestran la viabilidad técnica de digitalizar actividades cognitivas y constituyen referencias metodológicas valiosas, presentan limitaciones significativas en cuanto a su fundamentación clínica, la incorporación de modelos predictivos y la validación con usuarios reales. En términos generales, se trata de desarrollos con alcance académico acotado, sin continuidad como productos tecnológicos funcionales en entornos clínicos.

2.4.1 Características

En la Tabla 2.4 se presentan las características generales de los prototipos académicos de apoyo cognitivo identificados como referentes para el presente Trabajo Terminal.

Aspecto	Descripción
Origen	Universidades públicas y privadas de México y Latinoamérica
Plataforma	Móvil o web, según el proyecto
Actividades	Juegos de memoria, atención y percepción visual básicos
Instrumento clínico	No utilizan instrumentos validados como el MoCA
Modelos predictivos	No incorporan
Validación con usuarios	Limitada; generalmente con muestras pequeñas o simuladas
Costo	No comercial

Tabla 2.4. Características generales de prototipos académicos de apoyo cognitivo [8], [9].

La mayoría de estos prototipos implementan actividades cognitivas simples —como juegos de memoria secuencial, identificación de patrones visuales o ejercicios de atención sostenida— dentro de interfaces móviles o web desarrolladas con herramientas de libre acceso. Algunos incorporan registro básico de resultados, aunque sin análisis automatizado avanzado ni integración a modelos de aprendizaje automático.

2.4.2 Ventajas

- Desarrollados con herramientas de software de libre acceso, lo que elimina barreras económicas para su replicación y extensión.
- Demuestran la viabilidad técnica de digitalizar actividades cognitivas en plataformas móviles o web accesibles.
- Aportan experiencia metodológica y referencias de diseño de interfaz de usuario orientada a poblaciones adultas mayores.
- Algunos prototipos incorporan registro básico de resultados y retroalimentación visual al usuario.

2.4.3 Desventajas

- Limitada personalización de las actividades en función del perfil cognitivo individual del usuario; las actividades son generalmente fijas o con poca variabilidad adaptativa.
- No utilizan instrumentos de evaluación cognitiva clínicamente validados como el MoCA, por lo que sus resultados no tienen equivalencia diagnóstica.
- No incorporan modelos de clasificación supervisada ni estimación probabilística de riesgo de deterioro neurodegenerativo.
- Generalmente no contemplan seguimiento longitudinal estructurado ni generación de reportes orientados a profesionales de la salud.
- La validación con usuarios reales es limitada; en la mayoría de los casos se realizan pruebas con muestras pequeñas o con usuarios simulados.
- Su desarrollo no derivó en productos tecnológicos con continuidad ni mantenimiento activo.

2.5 SISTEMAS DE INVESTIGACION BASADOS EN APRENDIZAJE AUTOMÁTICO PARA LA DETECCIÓN DE DETERIORO COGNITIVO

En los últimos cinco años (2020–2025) se ha producido un notable incremento en la aplicación de técnicas de aprendizaje automático e inteligencia artificial explicable (IA-X) para apoyar la predicción y el manejo clínico del deterioro cognitivo y la enfermedad de Alzheimer [3], [4]. Estos modelos no solo buscan mejorar la precisión diagnóstica, sino también favorecer la transparencia de las decisiones mediante salidas interpretables que los profesionales clínicos puedan validar y comprender.

Entre los algoritmos de clasificación supervisada más empleados en este dominio destacan las Máquinas de Vectores de Soporte (MVS), los Bosques Aleatorios (BA) y la regresión logística. También se han explorado enfoques de aprendizaje de gradiente potenciado y redes neuronales profundas, principalmente sobre datos de neuroimagen, biomarcadores de líquido cefalorraquídeo e historiales clínicos electrónicos estructurados.

2.5.1 Principales Estudios y Resultados

En la Tabla 2.5 se presentan los principales estudios y sistemas de investigación identificados que aplican aprendizaje automático para la clasificación de deterioro cognitivo, junto con sus hallazgos más relevantes.

Estudio / Sistema	Hallazgo principal
Alatrany et al., 2024 [3]	Máquinas de Vectores de Soporte (MVS) alcanzan una puntuación F1 del 98.9 % en clasificación binaria y del 90.7 % en clasificación multiclase sobre datos del Centro Nacional Coordinador de Alzheimer
Vimbi et al., 2024 [5]	La combinación de Bosque Aleatorio y MVS sobre puntajes cognitivos e imágenes de resonancia magnética reporta una precisión del 91.2 %
Wang et al., 2024 [6]	Enfoques de aprendizaje de gradiente potenciado sobre historiales clínicos electrónicos estructurados alcanzan el 90.6 % de precisión
Tascedda et al., 2024 [7]	Estudios basados exclusivamente en datos neuropsicológicos reportan precisiones de aproximadamente el 80 % en la identificación de individuos en riesgo
Bucholc et al., 2023 [4]	Enfoque híbrido de aprendizaje automático para la predicción de conversión de Deterioro Cognitivo Leve a demencia con resultados competitivos frente a métodos basados en neuroimagen

Tabla 2.5. Principales estudios de investigación con apredizaje automático para clasificación de deterioro cognitico [3], [4], [5], [6], [7].

Los resultados reportados en estos estudios demuestran que los modelos de clasificación supervisada son herramientas técnicamente viables para identificar patrones cognitivos asociados a deterioro neurodegenerativo. En particular, los estudios basados exclusivamente en datos neuropsicológicos —sin requerir neuroimagen— son especialmente relevantes para el contexto del presente Trabajo Terminal, dado que la base de datos disponible contiene puntajes por dominio del MoCA, edad, escolaridad y diagnóstico clínico confirmado.

2.5.2 Ventajas

- Alta precisión reportada en la clasificación de deterioro cognitivo: las Máquinas de Vectores de Soporte alcanzan una puntuación F1 del 98.9 % en clasificación binaria [3], y la combinación con Bosques Aleatorios reporta precisiones del 91.2 % [5].
- La incorporación de técnicas de inteligencia artificial explicable —como los Valores de Shapley para Explicaciones Aditivas (SHAP) y las Explicaciones Interpretables y Agnósticas al Modelo de forma Local (LIME)— favorece la confianza clínica en los resultados generados por el modelo.
- Demuestran la viabilidad técnica y científica del enfoque de clasificación supervisada para datos cognitivos, lo que respalda la hipótesis del presente Trabajo Terminal.
- Algunos enfoques logran resultados competitivos utilizando únicamente datos neuropsicológicos, sin requerir neuroimagen ni biomarcadores de alto costo.

2.5.3 Desventajas

- Estos sistemas se presentan principalmente como contribuciones de investigación y no están integrados en plataformas accesibles para el usuario final ni para entornos clínicos de primer contacto.
- La mayoría requiere infraestructura especializada o datos de neuroimagen (resonancia magnética, tomografía por emisión de positrones) no disponibles en consulta general ni en niveles de atención primaria.
- No combinan la evaluación cognitiva digital con la estimación de riesgo y el seguimiento longitudinal en un único sistema integrado accesible.
- La reproducibilidad de los resultados puede verse afectada por diferencias en las bases de datos utilizadas, los criterios de selección de pacientes y los protocolos de validación empleados en cada estudio.

2.6 Tabla Comparativa

A partir del análisis de las soluciones presentadas en las secciones anteriores, en la Tabla 2.6 se presenta una comparativa estructurada de los criterios más relevantes para el contexto del presente Trabajo Terminal. Los criterios seleccionados permiten identificar las brechas existentes entre las soluciones actuales y la propuesta del sistema TT 2026-B141.

Criterio	Lumosity	CogniFit	CGPI 2004-1276	Prototipos Académicos	Sistemas con IA (investigación)	Propuesta TT 2026-B141
Evaluación cognitiva basada en MoCA	No	No	No	No	Parcial	Sí
Modelos de clasificación supervisada	No	No	No	No	Sí	Sí
Estimación probabilística de riesgo	No	No	No	No	Sí	Sí
Seguimiento longitudinal	Parcial	Parcial	No	No	No	Sí
Estimulación cognitiva personalizada	Sí	Sí	Sí	Parcial	No	Sí
Plataforma móvil	Sí	Sí	No	Parcial	No	Sí
Acceso no comercial	No	No	Sí	Sí	N/A	Sí
Validación del instrumento base	No	Parcial	No	No	Parcial	Sí

Tabla 2.6. Comparativa de soluciones existentes frente a la propuesta del TT 2026-B141.

Como se observa en la Tabla 2.6, ninguna de las soluciones analizadas integra simultáneamente los tres componentes fundamentales del sistema propuesto: evaluación cognitiva digital basada en el MoCA como instrumento clínico validado, modelos de clasificación supervisada para la estimación probabilística de riesgo neurodegenerativo, y seguimiento longitudinal del desempeño cognitivo con actividades de estimulación personalizadas. Las plataformas comerciales (Lumosity y CogniFit) abordan el componente de estimulación cognitiva, pero carecen de base clínica validada y de modelos predictivos. Los sistemas de investigación basados en aprendizaje automático incorporan modelos de alta precisión, pero no están integrados en plataformas accesibles ni contemplan el seguimiento longitudinal. Los prototipos y el Proyecto de Grupo de Investigación Académicos 2004-1276 aportan referencias metodológicas valiosas, pero no alcanzan el nivel de integración y validación propuesto.

En consecuencia, la propuesta del TT 2026-B141 representa una contribución original al área, al integrar en una única plataforma móvil de acceso no comercial los componentes de evaluación clínica, predicción de riesgo y estimulación cognitiva personalizada, apoyando la detección temprana de enfermedades neurodegenerativas sin sustituir el diagnóstico clínico profesional.

CAPITULO 3. MARCO TEÓRICO

El presente capitulo expone los fundamentos teóricos y conceptuales que sustentan el desarrollo del sistema propuesto. Se abordan las bases clinicas de las enfermedades neurodegenerativas, los instrumentos de evaluación cognitiva, los principios de la minería de datos y el aprendizaje automático, los marcos metodológicos y tecnológicos que guían el diseño e implementación del prototipo, y el conjunto de herramientas del stack tecnológico seleccionado.

3.1 ENFERMEDADES NEURODEGENERATIVAS

Las enfermedades neurodegenerativas son un conjunto heterogéneo de trastornos del sistema nervioso central caracterizados por la pérdida progresiva e irreversible de neuronas en regiones específicas del cerebro. Esta pérdida celular conlleva un deterioro gradual de funciones cognitivas, motoras o autonómicas, dependiendo de las estructuras afectadas [1].

3.1.1 Deterioro Cognitivo Leve (DCL)

El deterioro cognitivo leve (DCL) constituye una etapa intermedia entre el envejecimiento cognitivo normal y la demencia clínicamente establecida. Se caracteriza por una alteración objetiva de una o más funciones cognitivas -principalmente la memoria- que es mayor a la esperada para la edad y el nivel educativo del individuo, pero que no compromete de forma significativa la autonomía funcional [10].

Los criterios diagnósticos actuales del DCL, establecidos por Petersen et al. y revisados por el Instituto Nacional sobre el Envejecimiento (NIA), requieren: (1) deterioro cognitivo subjetivo reportado por el paciente o un informante, (2) evidencia objetiva de déficit en pruebas neuropsicológicas estandarizadas, (3) preservación de las actividades instrumentales de la vida diaria, y (4) ausencia de criterios para diagnóstico de demencia [10]. La tasa de conversión del DCL a demencia se estima entre el 8 y el 15 % anual, lo que subraya la importancia critica de su detección temprana [11].

3.1.2 Enfermedad de Alzheimer

La enfermedad de Alzheimer (EA) es la causa más frecuente de demencia, representando entre el 60 y el 80 % de todos los casos diagnosticados a nivel mundial [1]. Desde el punto de vista neuropatológico, se caracteriza por la acumulación extracelular de placas de péptido beta-amiloide (A-beta) y la formación de ovillos neurofibrilares intracelulares de proteína tau hiperfosforilada, procesos que generan disfunción sináptica, neuro inflamación y muerte neuronal progresiva [12].

Clínicamente, la EA se manifiesta inicialmente como déficit en la memoria episódica anterógrada, evolucionando hacia afectación del lenguaje (afasia), la praxis (apraxia) y el reconocimiento (agnosia), hasta la pérdida total de la autonomía en etapas avanzadas. Los criterios diagnósticos vigentes son los del Instituto Nacional sobre el Envejecimiento – Asociación de Alzheimer (NIA-AA), que incorporan tanto marcadores clínicos como biomarcadores de neuroimagen y líquido cefalorraquídeo

[1].

3.1.3 Deterioro Cognitivo Vascular

El deterioro cognitivo vascular (DCV) agrupa a las formas de deterioro cognitivo causadas por lesiones vasculares cerebrales, incluyendo infartos corticales o subcorticales, leucoaraiosis y microhemorragias. Representa entre el 5 y el 10 % de los casos de demencia, aunque con frecuencia coexiste con patología Alzheimer en forma de demencia mixta [12]. Su diagnóstico requiere la demostración de una relación temporal entre el evento vascular y el inicio del deterioro cognitivo, apoyada por neuroimagen.

3.2 PRUEBA MONTREAL COGNITIVE ASSESSMENT (MoCA)

La Montreal Cognitive Assessment (MoCA) es un instrumento de tamizaje cognitivo breve desarrollado por Nasreddine et al. en 2005, diseñado para la detección sensible del deterioro cognitivo leve. Ha sido validado en más de 35 idiomas y adoptado ampliamente en la práctica clínica internacional como herramienta de primera línea para la evaluación cognitiva [7].

3.2.1 Dominios Evaluados

La Tabla 3.2.1 describe los ocho dominios cognitivos evaluados por la prueba MoCA y las funciones que cada uno mide.

Dominio	Descripcion y funcion evaluada
Función visuoespacial y ejecutiva	Copia de un cubo tridimensional y trazado de un camino alternado (Trail Making). Evalúa planificación, organización y capacidad visuoconstructiva.
Denominación	Identificación de tres animales poco comunes (leon, camello, rinoceronte). Evalúa acceso léxico y reconocimiento visual.
Memoria	Registro y recuerdo diferido de cinco palabras tras un intervalo de interferencia. Evalúa memoria episódica verbal.
Atención	Repetición de dígitos en orden directo e inverso, tarea de detección y resta serial de 7. Evalúa atención sostenida y memoria de trabajo.
Lenguaje y fluidez verbal	Repetición de frases complejas y generación de palabras con la letra 'p' en un minuto. Evalúa producción y comprensión lingüística.
Abstracción	Identificación de la relación conceptual entre dos pares de palabras. Evalúa razonamiento abstracto.
Recuerdo diferido	Evocación libre de las cinco palabras registradas previamente, con claves semanticas si es necesario.
Orientación	Identificación de fecha, mes, ano, día, lugar y ciudad. Evalúa orientación temporal-espacial.

Tabla 3.1. Dominios cognitivos evaluados por la prueba MoCA [7].

3.2.2 Puntuación y Puntos de Corte

La puntuación máxima de la MoCA es de 30 puntos. Se añade un punto de bonificación cuando el nivel de escolaridad del evaluado es igual o inferior a 12 años. Los puntos de corte clínicamente establecidos se presentan en la Tabla 3.2.2.

Rango de puntuación	Clasificación diagnostica
26 - 30 puntos	Función cognitiva normal
18 - 25 puntos	Deterioro cognitivo leve (DCL)
10 - 17 puntos	Deterioro cognitivo moderado
< 10 puntos	Deterioro cognitivo severo / demencia probable

Tabla 3.2.2. Puntos de corte de la prueba MoCA y su clasificación diagnostica [7, 8].

Es importante considerar que variables sociodemográficas como la edad, el sexo y el nivel de escolaridad influyen significativamente en el desempeño en la MoCA. Estudios en poblaciones latinoamericanas han reportado la necesidad de ajustar los puntos de corte según el nivel educativo para reducir los falsos positivos en personas con escolaridad baja [8, 9].

3.3 MINERIA DE DATOS Y PREPROCESAMIENTO

La minería de datos es el proceso de extracción no trivial de patrones implícitos, previamente desconocidos y potencialmente útiles, a partir de grandes volúmenes de datos. En el contexto clínico, constituye una herramienta fundamental para identificar relaciones entre variables sociodemográficas, resultados de evaluaciones cognitivas y diagnósticos confirmados [24].

3.3.1 Proceso KDD

El proceso KDD comprende cinco etapas secuenciales: (1) selección de datos relevantes del conjunto de datos original, (2) preprocesamiento y limpieza para eliminar ruido e inconsistencias, (3) transformación y reducción dimensional, (4) aplicación de algoritmos de minería de datos, y (5) evaluación e interpretación de los patrones descubiertos. En el presente proyecto, este proceso se aplica sobre una base de datos clínica con diagnostico confirmado, edad, escolaridad y puntajes por dominio del MoCA.

3.3.2 Técnicas de Preprocesamiento

- Tratamiento de valores faltantes: imputación por media o mediana para variables continuas; imputación por moda o eliminación para variables categoricas.
- Normalización y estandarizacion: escalado de características al rango [0, 1] (Min-Max) o transformación a distribucion de media cero y desviación estandar unitaria (Z-score), necesario para algoritmos sensibles a la magnitud como MVS.
- Codificación de variables categoricas: transformación de variables nominales (sexo, diagnostico) mediante codificación one-hot o label encoding según el algoritmo empleado.
- Detección y manejo de valores atípicos: identificacion mediante rango intercuartílico (IQR) o z-score; tratamiento por eliminación o winzorizacion.
- Balanceo de clases: aplicación de SMOTE o submuestreo aleatorio cuando las clases diagnosticas presentan distribución desbalanceada.

3.3.3 Seleccion de Caracteristicas

La seleccion de caracteristicas (feature selection) tiene como objetivo identificar el subconjunto minimo de variables que maximiza el poder predictivo del modelo, reduciendo la dimensionalidad y mitigando el riesgo de sobreajuste. Las tecnicas empleadas en este proyecto incluyen metodos de filtrado basados en la correlacion de Pearson y la informacion mutua, asi como metodos envolventes (wrapper) como la eliminacion recursiva de caracteristicas (RFE) y la importancia de caracteristicas derivada del modelo Bosque Aleatorio [24].

3.4 APRENDIZAJE AUTOMATICO

El aprendizaje automatico (Machine Learning, ML) es una rama de la inteligencia artificial que desarrolla algoritmos capaces de aprender patrones a partir de datos y generalizar ese conocimiento para realizar predicciones sobre nuevas instancias, sin ser explicitamente programados para cada caso particular. En la clasificacion supervisada, el algoritmo aprende a partir de un conjunto de entrenamiento con etiquetas de clase conocidas [25].

3.4.1 Regresion Logistica

La regresion logistica es un modelo de clasificacion lineal que estima la probabilidad de pertenencia a una clase mediante la funcion sigmoide aplicada a una combinacion lineal de las caracteristicas de entrada. Para la clasificacion binaria, el modelo se define como:

$$P(y = 1|x) = \frac{1}{1 + e^{-(\beta_0 + \sum_{i=0}^{n} \beta_i x_i)}}$$

$P(y = 1|x)$ *: Es la probabilidad condicionada de que la variable dependiente y sea 1 (presencia de la condición) dado un conjunto de características x*

e*: Es la constante de Euler (aproximadamente 2.71828), base de los logaritmos naturales.*

β_0*: Representa el intercepto o sesgo del modelo; es el valor cuando todas las variables de entrada son cero*

β_i*: Son los coeficientes del modelo que indican la contribución o peso de cada variable predictora.*

x_i*: Representa las características de entrada o variables independientes (como la edad, escolaridad o puntajes del MoCA).*

El modelo ofrece la ventaja de producir probabilidades directamente interpretables y coeficientes que permiten evaluar la contribución de cada variable predictora [25].

3.4.2 Maquinas de Soporte Vectorial (MVS)

Las Maquinas de Soporte Vectorial (Support Vector Machines, SVM) son clasificadores que buscan el hiperplano de separacion optimo entre clases, maximizando el margen entre los vectores de soporte -instancias mas cercanas al limite de decision- de cada clase. Para datos no linealmente separables, MVS utiliza el truco del kernel para transformar el espacio de caracteristicas a una dimension superior donde los datos sean separables [25].
El problema de optimizacion primal de MVS se formula como:

$$min\ \frac{1}{2} \| w \|^2 \quad sujeto\ a: y_i(w * x_i + b) \geq 1$$

Para la version de margen suave (soft margin), se incorpora una variable de holgura xi y

un parametro de regularizacion C que controla el compromiso entre el margen y el error de clasificacion. Los kernels mas empleados en clasificacion cognitiva son el lineal, el polinomial y el RBF (Radial Basis Function) [17].

w: Es el vector normal al hiperplano de separación; define la orientación del límite de decisión.
$\| w \|$: Representa la norma euclidiana del vector w. Al minimizarla, se maximiza el margen entre las clases.
x_i: Es el vector de características de la instancia i-ésima.
y_i: Es la etiqueta de clase de la instancia (normalmente +1 o -1).
b: Es el sesgo (bias), que permite desplazar el hiperplano fuera del origen.

3.4.3 Bosque Aleatorio (Random Forest)

Bosque Aleatorio (Random Forest) es un metodo de ensemble que construye multiples arboles de decision durante el entrenamiento y agrega sus predicciones mediante votacion mayoritaria (clasificacion) o promedio (regresion). Cada arbol se entrena sobre un subconjunto aleatorio de las instancias (bootstrap) y, en cada nodo de division, solo se considera un subconjunto aleatorio de m caracteristicas, donde $m = \sqrt{p}$ siendo p el numero total de caracteristicas [25].

$$\hat{y} = arg\ max_c \sum_{i=1}^{T} I(h_i(x) = c)$$

$\hat{y}$: Es la predicción final del modelo (la clase con más votos).

$arg\ max_c$: Es la función que selecciona la clase c que maximiza el valor de la suma.

T: Representa el número total de árboles en el bosque.

$h_i(x)$: Es la predicción individual realizada por el árbol i-ésimo para la entrada x.

$I()$: Es una función indicadora que devuelve 1 si la predicción del árbol coincide con la clase c, y 0 en caso contrario.

$m = \sqrt{p}$: Donde m es el subconjunto aleatorio de características consideradas en cada división y p es el número total de variables

Bosque Aleatorio es robusto al sobreajuste, maneja bien datos desbalanceados y proporciona una medida natural de importancia de caracteristicas basada en la reduccion del indice de Gini. Estudios recientes reportan precisiones superiores al 91 % en clasificacion cognitiva multiclase [15].

3.4.4 Métricas de Evaluación

La evaluación del desempeño de los modelos de clasificación se realizará mediante las siguientes métricas, derivadas de la matriz de confusión (VP: verdaderos positivos, VN: verdaderos negativos, FP: falsos positivos, FN: falsos negativos):

Metrica	Formula	Interpretacion
Exactitud (Accuracy)	$\frac{VP + VN}{VP + VN + FP + FN}$	Proporción de clasificaciones correctas totales
Sensibilidad (Recall)	$\frac{VP}{VP + FN}$	Capacidad de detectar casos positivos reales (critico en diagnostico clínico)
Especificidad	$\frac{VN}{VN + FP}$	Capacidad de identificar correctamente los negativos
Precisión (Precision)	$\frac{VP}{VP + FP}$	Proporción de positivos predichos que son reales
F1-Score	$2 * \frac{\text{Precisión} * \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}}$	Media armónica entre precisión y sensibilidad
AUC-ROC	Area bajo la curva ROC	Capacidad discriminativa del modelo; AUC > 0.9 indica excelente desempeño

Tabla 3.4.4.
Métricas de evaluación de modelos de clasificación supervisada

3.4.5 Validacion Cruzada

La validacion cruzada de k pliegues (k-fold cross-validation) es la tecnica estandar para estimar el desempeno generalizable de un modelo cuando el conjunto de datos es de tamano moderado. El conjunto de datos se divide en k subconjuntos de igual tamano; el modelo se entrena k veces, utilizando en cada iteracion k-1 pliegues para entrenamiento y el pliegue restante para validacion. La metrica final es el promedio de las k evaluaciones. Para este proyecto se empleara k = 5 o k = 10 segun el tamano de la muestra disponible [25].

3.5 SISTEMAS DE APOYO A LA DECISION CLINICA (CDSS)

Los Sistemas de Apoyo a la Decision Clinica (Clinical Decision Support Systems, CDSS) son sistemas de informacion disenados para asistir a los profesionales de la salud en la toma de decisiones clinicas, integrando datos del paciente con bases de conocimiento medico para generar recomendaciones, alertas o evaluaciones de riesgo especificas [26]. Los CDSS modernos se clasifican en dos grandes categorias: (1) sistemas basados en

reglas (rule-based), que emplean logica explicita codificada por expertos clinicos, y (2) sistemas basados en aprendizaje automatico (ML-based), que derivan sus reglas de decision de forma inductiva a partir de datos historicos. El prototipo propuesto en este Trabajo Terminal pertenece a la segunda categoria.

3.5.1 Componentes Funcionales de un CDSS

- Base de conocimiento: conjunto de reglas, modelos o patrones aprendidos que fundamentan las recomendaciones del sistema.
- Motor de inferencia: mecanismo que aplica la base de conocimiento a los datos del paciente para generar salidas.
- Mecanismo de comunicacion: interfaz que presenta los resultados al usuario de forma comprensible y accionable.
- Modulo de datos del paciente: integracion de informacion clinica, demografica y de evaluacion cognitiva.

3.5.2 Explicabilidad e Interpretabilidad (XAI)

En el contexto medico, la aceptacion de un CDSS por parte de los profesionales de la salud depende en gran medida de la transparencia de sus decisiones. La inteligencia artificial explicable (Explainable AI, XAI) proporciona mecanismos para que los modelos de ML comuniquen, ademas del resultado, una justificacion comprensible de por que se llego a dicha conclusion [14].

Dos de las tecnicas de XAI mas empleadas en aplicaciones clinicas son: (1) SHAP (SHapley Additive exPlanations), basado en la teoria de juegos cooperativos, que asigna a cada caracteristica un valor de contribucion aditiva sobre la prediccion; y (2) LIME (Local Interpretable Model-agnostic Explanations), que aproxima localmente el comportamiento del modelo con un modelo interpretable lineal. Ambas tecnicas seran consideradas en la etapa de evaluacion del prototipo [14].

3.6 APLICACIONES MOVILES EN SALUD (mHealth)

El termino mHealth (mobile Health) hace referencia al uso de dispositivos moviles -como telefonos inteligentes y tabletas- para la prestacion de servicios y la gestion de informacion en el ambito de la salud. La OMS define mHealth como la practica medica y de salud publica apoyada por dispositivos moviles [27].

Las aplicaciones mHealth han demostrado ser herramientas efectivas para el monitoreo de condiciones cronicas, la adherencia a tratamientos y la realizacion de evaluaciones cognitivas breves en entornos fuera de la clinica. Para el diseno de aplicaciones mHealth orientadas a poblaciones adultas mayores, los principios de usabilidad establecidos por Nielsen -visibilidad del estado del sistema, correspondencia entre el sistema y el mundo real, control y libertad del usuario, consistencia y estandares- adquieren especial relevancia [28].

En el contexto de evaluacion cognitiva, estudios recientes han validado la equivalencia entre versiones digitales de instrumentos como la MoCA y su aplicacion tradicional en papel, reportando coeficientes de correlacion intraclase (ICC) superiores a 0.85, indicativos de alta concordancia [6].

3.7 METODOLOGIA EN V

La metodologia en V (V-Model) es un modelo de proceso de desarrollo de software que extiende el modelo en cascada incorporando de forma explicita las actividades de verificacion y validacion correspondientes a cada fase de desarrollo. Su denominacion proviene de la representacion grafica en forma de V: el lado izquierdo corresponde a las fases de definicion y diseno, mientras que el lado derecho representa las fases de pruebas asociadas, conectadas simetricamente con las fases de desarrollo [29].

3.7.1 Fases del Modelo en V

La Tabla 3.7.1 presenta la correspondencia entre las fases de desarrollo y las fases de validacion del modelo en V aplicado al presente proyecto.

Fase de desarrollo (lado izquierdo)	Fase de validacion correspondiente (lado derecho)
Analisis de requerimientos del sistema	Pruebas de aceptacion del usuario (UAT)
Diseno del sistema y arquitectura	Pruebas de sistema
Diseno de modulos y componentes	Pruebas de integracion
Codificacion / implementacion	Pruebas unitarias

Tabla 3.7.1. Correspondencia entre fases de desarrollo y validacion en el modelo en V [29].

3.7.2 Justificacion de la Metodologia para el Proyecto

El modelo en V resulta adecuado para el presente Trabajo Terminal por las siguientes razones: (1) los requerimientos del sistema estan bien definidos desde el inicio a partir del analisis clinico y del instrumento MoCA, lo que reduce la incertidumbre propia de metodologias agiles; (2) la naturaleza del prototipo demanda una validacion rigurosa y sistematica de cada componente -especialmente del modelo de ML- antes de la integracion total del sistema; (3) el tiempo acotado de dos semestres (TT1 y TT2) favorece una planificacion secuencial y predecible; y (4) los entregables de cada fase son verificables e inspeccionables por la directora del proyecto [29].

3.8 ARQUITECTURA TECNOLOGICA DEL SISTEMA

El sistema propuesto se estructura en capas funcionales claramente delimitadas: frontend movil, backend con API REST, analisis de datos, aprendizaje automatico, visualizacion, persistencia de datos, infraestructura en nube y seguridad.

Capa	Tecnologia	Funcion principal
Frontend movil	React Native	Desarrollo de la interfaz de usuario para Android. Permite compartir logica entre plataformas y mantener un unico codigo base.
Backend / API	Python + FastAPI	Gestion de la logica de negocio, autenticacion de usuarios, enrutamiento de peticiones y exposicion de los modelos de ML como servicios REST.
Analisis de datos	NumPy	Operaciones vectorizadas y matriciales sobre puntajes MoCA y variables sociodemograficas durante el preprocesamiento.
Analisis de datos	pandas	Carga, limpieza, transformacion y analisis exploratorio de la base de datos clinica. Manejo de valores faltantes y codificacion de variables.

Aprendizaje automatico	scikit-learn	Implementacion y evaluacion de Regresion Logistica, MVS y Bosque Aleatorio. Validacion cruzada y metricas de desempeno.
Aprendizaje automatico	imbalanced-learn	Aplicacion de SMOTE para el balanceo de clases diagnosticas en la base de datos de entrenamiento.
Aprendizaje automatico	SHAP	Generacion de explicaciones interpretables mediante Valores de Shapley, para la justificacion clinica de la estimacion de riesgo.
Visualizacion	Matplotlib / Seaborn	Generacion de graficas de evolucion longitudinal y curvas COR durante la validacion del modelo.
Base de datos	PostgreSQL	Almacenamiento relacional de usuarios, perfiles, resultados de evaluaciones y registros de seguimiento longitudinal.
ORM	SQLAlchemy	Mapeo objeto-relacional entre modelos Python y tablas PostgreSQL, facilitando las operaciones CRUD.
Nube	Azure App Service	Despliegue del backend FastAPI como servicio administrado, con escalabilidad automatica y balanceo de carga.
Nube	Azure Database for PostgreSQL	Hospedaje administrado de la base de datos con copias de seguridad, cifrado en reposo y alta disponibilidad.
Nube	Azure Blob Storage	Almacenamiento de reportes PDF y modelos serializados de aprendizaje automatico.
Seguridad	JWT + bcrypt	Autenticacion mediante Tokens Web JSON con expiracion configurable. Cifrado de contrasenas con hash bcrypt y sal aleatoria.
Reportes	ReportLab	Generacion programatica de reportes en PDF con puntajes por dominio, graficas de evolucion y estimacion de riesgo.

Tabla 3.8. Stack tecnologico del sistema TT 2026-B141.

3.9 HERRAMIENTAS PARA EL DESARROLLO MOVIL (FRONT-END)

3.9.1 React Native

React Native es un marco de trabajo (framework) de codigo abierto desarrollado por Meta, basado en JavaScript y React, que permite construir aplicaciones moviles nativas para Android e iOS a partir de un unico codigo base. A diferencia de los enfoques de aplicaciones web empaquetadas (WebView), React Native compila sus componentes en elementos de interfaz de usuario (IU) nativos de cada plataforma, lo que garantiza un rendimiento y una experiencia visual indistinguibles de las aplicaciones desarrolladas en Java/Kotlin (Android) o Swift/Objective-C (iOS) [30].

Su arquitectura se apoya en el motor de JavaScript Hermes, optimizado para dispositivos moviles, y en un puente de comunicacion (bridge) con los modulos nativos del sistema operativo. La gestion del estado de la aplicacion se realiza tipicamente mediante hooks de React (useState, useEffect, useContext) o bibliotecas de manejo de estado como Redux o Zustand.

En el contexto de este proyecto, React Native es la tecnologia base del modulo de interfaz de usuario de la aplicacion movil para Android. Su implementacion es fundamental para

garantizar una IU fluida, accesible y optimizada bajo principios de usabilidad para adultos mayores, facilitando la presentacion interactiva de los dominios del MoCA, la captura estructurada de respuestas y la visualizacion de los reportes de riesgo cognitivo generados por el sistema.

3.10 HERRAMIENTAS PARA EL DESARROLLO DE SERVICIOS (BACK-END)

3.10.1 Python

Python es un lenguaje de programacion interpretado, de alto nivel y proposito general, cuya sintaxis clara y expresiva favorece un desarrollo eficiente y mantenible. Fue seleccionado como el lenguaje principal del backend debido a su ecosistema maduro para el desarrollo de servicios web y su integracion nativa con las principales bibliotecas de analisis de datos e inteligencia artificial (NumPy, pandas, scikit-learn, SHAP). En la version 3.10 o superior, Python ofrece soporte robusto para programacion asincrona mediante asyncio, patron de diseno esencial para la arquitectura del servidor propuesto [31].

3.10.2 FastAPI

FastAPI es un marco de trabajo web de alto rendimiento para la construccion de APIs con Python, basado en los estandares OpenAPI y JSON Schema. Destaca por su soporte nativo para programacion asincrona (async/await), la validacion automatica de datos mediante Pydantic y la generacion automatica de documentacion interactiva (Swagger UI y ReDoc). En comparacion con marcos alternativos como Flask o Django REST Framework, FastAPI ofrece un rendimiento significativamente superior en escenarios de concurrencia, siendo comparable con Node.js y Go en benchmarks estandar [32].
En el presente sistema, FastAPI actua como el nucleo del backend: gestiona la autenticacion de usuarios mediante JWT, expone los endpoints REST para el modulo de evaluacion cognitiva, el seguimiento longitudinal y la estimulacion cognitiva, y encapsula la llamada a los modelos de clasificacion supervisada entrenados, devolviendo la estimacion de riesgo como respuesta JSON al cliente movil.

3.10.3 Transferencia de Estado Representacional (REST)

REST (Representational State Transfer) es un estilo de arquitectura de software que define un conjunto de restricciones para la creacion de servicios web escalables y desacoplados. Sus principios fundamentales incluyen la comunicacion sin estado (stateless), la identificacion de recursos mediante URIs, la manipulacion de recursos a través de metodos HTTP estandar (GET, POST, PUT, DELETE) y la transferencia de

representaciones en formatos como JSON [33].
En este prototipo, la arquitectura REST permite el intercambio de datos estructurados entre la aplicacion movil (cliente) y el servidor (FastAPI) a traves del protocolo HTTPS, garantizando que el sistema sea modular, escalable e interoperable. Cada modulo funcional del sistema -evaluacion, prediccion, seguimiento y estimulacion- corresponde a un conjunto de recursos REST con endpoints bien definidos.

3.11 BIBLIOTECAS PARA EL ANALISIS DE DATOS CLINICOS

3.11.1 NumPy

NumPy (Numerical Python) es la biblioteca fundamental para la computacion cientifica en Python. Introduce el objeto ndarray, un arreglo multidimensional de tipo homogeneo que permite la ejecucion de operaciones vectorizadas y matriciales con un rendimiento cercano al del lenguaje C, gracias a su implementacion en C con BLAS y LAPACK como backends opcionales [34].
En el proceso de preprocesamiento de la base de datos clinica, NumPy se utiliza para realizar operaciones aritmeticas y estadisticas de alta velocidad sobre los puntajes por dominio del MoCA, el calculo de estadisticos descriptivos (media, desviacion estandar, percentiles) y la transformacion de matrices de caracteristicas previo al entrenamiento de los modelos de clasificacion supervisada.

3.11.2 pandas

pandas es una biblioteca de codigo abierto construida sobre NumPy que proporciona estructuras de datos de alto nivel -principalmente DataFrame y Series- para la manipulacion y el analisis de datos tabulares. Su flexibilidad la convierte en la herramienta estandar para el proceso KDD (Knowledge Discovery in Databases) en Python [35].
Dentro del flujo de preprocesamiento del presente proyecto, pandas se emplea para: (1) la carga de la base de datos clinica desde fuentes CSV o SQL; (2) la identificacion y tratamiento de valores faltantes mediante imputacion por media o mediana; (3) la codificacion de variables categoricas (sexo, diagnostico) mediante one-hot encoding o label encoding; (4) la normalizacion y estandarizacion de variables numericas; y (5) la seleccion y transformacion de caracteristicas para el entrenamiento de los modelos. Su integracion con scikit-learn y SQLAlchemy facilita el flujo completo desde la base de datos relacional hasta el modelo de prediccion.

3.12 HERRAMIENTAS DE APRENDIZAJE AUTOMATICO

3.12.1 scikit-learn

scikit-learn es la biblioteca de referencia para el aprendizaje automatico supervisado y no supervisado en Python. Proporciona implementaciones eficientes y unificadas de los principales algoritmos de clasificacion, regresion, agrupamiento y reduccion de dimensionalidad, bajo una API consistente (fit/predict/transform) que facilita la integracion

de distintos modelos en pipelines reproducibles [36].
En el presente proyecto, scikit-learn provee las implementaciones de los tres modelos de clasificacion supervisada evaluados: Regresion Logistica (LogisticRegression), Maquinas de Vectores de Soporte (SVC con kernels lineal y RBF) y Bosque Aleatorio (RandomForestClassifier). Adicionalmente, se emplean sus modulos de validacion cruzada (cross_val_score, StratifiedKFold), busqueda de hiperparametros (GridSearchCV) y metricas de evaluacion (classification_report, roc_auc_score, confusion_matrix) para la seleccion y validacion rigurosa del modelo final.

3.12.2 imbalanced-learn y SMOTE

imbalanced-learn es una biblioteca de Python compatible con la API de scikit-learn, especializada en el manejo de conjuntos de datos con distribucion de clases desbalanceada. Entre sus tecnicas mas utilizadas destaca el Sobremuestreo Sintetico de la Clase Minoritaria, conocido por sus siglas en ingles como SMOTE (Synthetic Minority Over-sampling Technique). SMOTE genera nuevas instancias sinteticas de las clases minoritarias mediante interpolacion lineal entre instancias existentes y sus vecinos mas proximos en el espacio de caracteristicas, a diferencia de tecnicas de duplicacion aleatoria que no aumentan la variabilidad del conjunto de entrenamiento [37].
Esta tecnica es critica en el presente proyecto dado que la base de datos clinica presenta una distribucion tipicamente desbalanceada entre las clases diagnosticas (deterioro cognitivo leve, enfermedad de Alzheimer, deterioro cognitivo vascular y cognicion normal). Sin balanceo, los modelos tienden a maximizar la exactitud global priorizando las clases mayoritarias, lo que reduce la sensibilidad -metrica clinicamente prioritaria- para detectar casos reales de deterioro cognitivo.

3.12.3 SHAP (Valores de Shapley para Explicaciones Aditivas)

SHAP (SHapley Additive exPlanations) es un marco unificado para la interpretacion de modelos de aprendizaje automatico, fundamentado en la teoria de juegos cooperativos de Shapley. Asigna a cada caracteristica de entrada un valor de contribucion aditiva (valor SHAP) sobre la prediccion de una instancia especifica, de forma que la suma de todos los valores SHAP mas el valor base del modelo equivale a la prediccion del modelo para esa instancia [38].
En el contexto clinico del presente sistema, SHAP permite generar Inteligencia Artificial Explicable (XAI): para cada estimacion de riesgo producida por el modelo de clasificacion, el sistema identifica y comunica al profesional de la salud que variables -por ejemplo, la puntuacion en el dominio de memoria diferida, la edad o el nivel de escolaridad- tuvieron mayor influencia positiva o negativa en la estimacion. Esta transparencia es fundamental para la aceptacion del sistema como herramienta de apoyo a la decision clinica, en linea con los principios de los CDSS descritos en la seccion 3.5.

3.13 HERRAMIENTAS DE VISUALIZACION Y REPORTES

3.13.1 Matplotlib y Seaborn

Matplotlib es la biblioteca de visualizacion de datos de referencia en Python, que proporciona control granular sobre todos los elementos de una figura (ejes, escalas, colores, anotaciones). Seaborn es una capa de alto nivel construida sobre Matplotlib que simplifica la creacion de graficas estadisticas con estilos modernos y una API mas

concisa, orientada a la exploracion de datos [39].
En el presente proyecto, ambas bibliotecas se utilizan durante la fase de analisis y validacion del modelo para: (1) representar la distribucion de puntajes por dominio del MoCA segun clase diagnostica; (2) generar las curvas COR (Caracteristica Operativa del Receptor) para comparar la capacidad discriminativa de los modelos evaluados; (3) visualizar la importancia de caracteristicas derivada del Bosque Aleatorio; y (4) generar graficas de seguimiento longitudinal del desempeno cognitivo del usuario que se integran en los reportes PDF.

3.13.2 ReportLab

ReportLab es una biblioteca de Python para la generacion programatica y dinamica de documentos en formato PDF (Portable Document Format). Permite componer documentos con estructura compleja, incluyendo texto con estilos tipograficos, tablas, graficas vectoriales e imagenes rasterizadas, a partir de instrucciones de alto nivel basadas en el modelo de platillas (templates) de ReportLab [40].
En el sistema propuesto, ReportLab es responsable de la generacion automatica de reportes clinicos descargables que incluyen: el perfil cognitivo del usuario con puntajes por dominio del MoCA, la grafica de evolucion longitudinal de las evaluaciones previas, la estimacion probabilistica de riesgo producida por el modelo de clasificacion, los valores SHAP de las variables mas influyentes y las recomendaciones de actividades de estimulacion. Estos reportes estan disenados para ser consultados por profesionales de la salud como apoyo complementario a la evaluacion clinica.

3.14 GESTION DE BASES DE DATOS Y PERSISTENCIA

3.14.1 PostgreSQL

PostgreSQL es un sistema de gestion de base de datos relacional de codigo abierto, orientado a objetos, con mas de 35 anos de desarrollo activo. Se caracteriza por su plena conformidad con el estandar SQL, su extensibilidad mediante tipos de datos personalizados, funciones almacenadas y extensiones, y su solidez en el manejo de transacciones ACID (Atomicidad, Consistencia, Aislamiento y Durabilidad) [41].
En el presente prototipo, PostgreSQL se encarga del almacenamiento estructurado y seguro de toda la informacion sensible del sistema: perfiles de usuario (datos sociodemograficos y clinicos), resultados historicos de evaluaciones cognitivas con puntajes por dominio, registros del modulo de seguimiento longitudinal y catalogo de actividades de estimulacion. Su seleccion frente a alternativas como MySQL o SQLite se justifica por su mayor robustez en el manejo de datos clinicos, su soporte nativo para tipos JSON y su integracion nativa con Azure Database for PostgreSQL en la capa de nube.

3.14.2 SQLAlchemy y el Patron ORM

SQLAlchemy es la biblioteca ORM (Object-Relational Mapping) de referencia en el ecosistema Python. Proporciona dos niveles de abstraccion: (1) el Core, que ofrece una interfaz de alto nivel para la construccion y ejecucion de consultas SQL sin abandonar el paradigma relacional; y (2) el ORM, que establece un mapeo declarativo entre las clases de Python y las tablas de la base de datos, permitiendo operar sobre los datos como si fueran objetos del lenguaje [42].
En el sistema propuesto, SQLAlchemy es la capa de acceso a datos del backend FastAPI: define los modelos relacionales (Usuario, Evaluacion, DominioCognitivo, SeguimientoLongitudinal, ActividadEstimulacion), gestiona las sesiones de conexion a

PostgreSQL y facilita las operaciones CRUD (Creacion, Lectura, Actualizacion y Eliminacion) mediante una API orientada a objetos, eliminando la necesidad de escribir consultas SQL manualmente y reduciendo el riesgo de inyeccion SQL.

3.15 INFRAESTRUCTURA Y SERVICIOS EN LA NUBE

El despliegue del sistema se realiza sobre Microsoft Azure, plataforma de computo en la nube que ofrece servicios administrados de hospedaje, almacenamiento y base de datos bajo modelos de pago por uso. La eleccion de Azure responde a la disponibilidad de creditos academicos para estudiantes del IPN a traves del programa Azure for Students, que proporciona acceso a los servicios necesarios sin costo adicional para el prototipo [43].

3.15.1 Azure App Service

Azure App Service es una plataforma como servicio (PaaS) para el hospedaje de aplicaciones web, APIs REST y backends moviles. Soporta multiples entornos de ejecucion, incluyendo Python 3.10+, y permite el despliegue continuo mediante integracion con repositorios Git. Garantiza la alta disponibilidad del prototipo mediante balanceo de carga automatico y ofrece escalabilidad vertical y horizontal segun la demanda [43].
En este sistema, Azure App Service hospeda la aplicacion FastAPI como servicio web administrado, eliminando la necesidad de gestionar la infraestructura de servidor subyacente. La comunicacion entre la aplicacion movil y el backend se realiza mediante HTTPS, con certificado SSL gestionado automaticamente por la plataforma.

3.15.2 Azure Database for PostgreSQL

Azure Database for PostgreSQL es el servicio administrado de base de datos relacional PostgreSQL en la plataforma Azure. Ofrece copias de seguridad automaticas con retencion configurable, cifrado en reposo y en transito, alta disponibilidad mediante replicas en zona, y parches automaticos del motor de base de datos sin interrupcion del servicio [43].
En el presente prototipo, este servicio hospeda la instancia de PostgreSQL que almacena

los datos clinicos y de usuario del sistema. Su uso como servicio administrado elimina la necesidad de gestionar manualmente la configuracion, los backups y las actualizaciones de seguridad del motor de base de datos, reduciendo la complejidad operativa del prototipo academico.

3.15.3 Azure Blob Storage

Azure Blob Storage es el servicio de almacenamiento de objetos de Azure, optimizado para datos no estructurados de gran volumen como archivos binarios, imagenes y documentos. En el sistema propuesto, Azure Blob Storage cumple dos funciones: (1) almacenamiento persistente de los modelos de aprendizaje automatico serializados (archivos .pkl o .joblib) que son cargados por el backend al iniciar el servicio; y (2) repositorio de los reportes en formato PDF generados por ReportLab para cada usuario, accesibles mediante URLs firmadas con tiempo de expiracion configurable [43].

3.16 SEGURIDAD Y AUTENTICACION

El manejo de datos clinicos y personales sensibles impone requerimientos especificos de seguridad que el sistema aborda en dos niveles: la autenticacion de usuarios mediante tokens y el cifrado de credenciales almacenadas.

3.16.1 JWT (Tokens Web de JSON)

JWT (JSON Web Token) es un estandar abierto (RFC 7519) para la transmision segura de informacion entre partes como objetos JSON firmados digitalmente. Un JWT se compone de tres partes codificadas en Base64url: el encabezado (header), con el algoritmo de firma; la carga util (payload), con las afirmaciones (claims) sobre el usuario; y la firma (signature), que verifica la integridad del token [44].
En el presente sistema, los JWT permiten implementar autenticacion sin estado (stateless): tras el inicio de sesion, el servidor genera un token firmado con una clave secreta y lo devuelve al cliente movil. En cada peticion subsecuente, el cliente incluye el token en el encabezado HTTP Authorization (esquema Bearer). El servidor verifica la firma y la vigencia del token sin necesidad de consultar la base de datos, lo que reduce la latencia y escala horizontalmente sin requerir sesiones compartidas. Los tokens se emiten con un tiempo de expiracion configurable (por defecto 24 horas).

3.16.2 bcrypt

bcrypt es una funcion de derivacion de claves (KDF) basada en el cifrado Blowfish, disenada especificamente para el almacenamiento seguro de contrasenias. Incorpora por diseno un factor de costo (work factor) ajustable que controla el numero de iteraciones del algoritmo, permitiendo incrementar la resistencia computacional a medida que el hardware evoluciona. Ademas, incluye una sal (salt) aleatoria de 16 bytes integrada en el hash resultante, lo que neutraliza los ataques de tabla arco iris (rainbow tables) y garantiza que

dos contrasenias identicas produzcan hashes distintos [45].
En el presente sistema, bcrypt es la funcion de hashing empleada para almacenar las contrasenias de los usuarios en la base de datos PostgreSQL. Al registrarse, la contrasenia es procesada por bcrypt con un factor de costo de 12 (equivalente a 4,096 iteraciones), produciendose un hash de 60 caracteres que se almacena en la base de datos. En el inicio de sesion, la contrasenia ingresada se compara con el hash almacenado mediante bcrypt.checkpw, sin requerir descifrado, garantizando que la contrasenia en texto plano nunca se persista ni se transmita al servidor.

CAPÍTULO 4 ÁRBOL DE PROBLEMAS

El árbol de problemas permite visualizar de manera estructurada las causas y consecuencias del problema central identificado: la detección tardía del deterioro cognitivo asociado a enfermedades neurodegenerativas.

4.1 *Problema Central*

Detección tardía de los primeros signos de deterioro cognitivo leve, enfermedad de Alzheimer y deterioro cognitivo vascular en la población adulta mayor en México.

4.2 Causas

Causas directas	• Ausencia de herramientas digitales accesibles que integren evaluación cognitiva estandarizada, modelos predictivos y seguimiento longitudinal en un solo sistema. • Aplicación del MoCA limitada a entornos clínicos presenciales con registro manual, sin análisis automatizado de patrones históricos. • Confusión de los síntomas iniciales del deterioro cognitivo con cambios normales del envejecimiento o estrés, retrasando la consulta especializada.

Causas subyacentes	• Brecha entre los avances en inteligencia artificial aplicada a salud y las herramientas disponibles en la práctica clínica cotidiana. • Insuficiente capacitación de médicos de primer contacto para aplicar e interpretar pruebas de tamizaje cognitivo [2]. • Escasez de sistemas de información que permitan integrar y analizar datos cognitivos longitudinales del paciente.

4.3 Consecuencias

Consecuencias directas	• Intervención terapéutica y preventiva en etapas avanzadas de la enfermedad, cuando las opciones de tratamiento son más limitadas. • Progresión acelerada del deterioro cognitivo por falta de estimulación y seguimiento oportuno. • Mayor carga para los cuidadores y las familias de los pacientes.
Consecuencias a largo plazo	• Incremento de los costos de atención médica y social asociados a la dependencia progresiva de los pacientes con demencia [21]. • Deterioro de la calidad de vida del paciente y pérdida de autonomía en etapas que podrían haberse ralentizado con intervención temprana. • Aumento de la prevalencia de demencia en México, que podría alcanzar los 3.5 millones de personas para 2050

CAPITULO 5. ALCANCES Y LIMITACIONES

5.1. Alcances

El presente Trabajo Terminal contempla el desarrollo de un prototipo funcional de sistema inteligente orientado al apoyo en la detección temprana del deterioro cognitivo. Los alcances del proyecto incluyen:

- El diseño e implementación de una plataforma digital que permita la captura estructurada de resultados inspirados en los dominios del MoCA.
- El análisis de una base de datos clínica con diagnóstico confirmado, edad, escolaridad y puntajes cognitivos.
- La implementación de modelos de clasificación supervisada (regresión logística, SVM y Random Forest) para identificar patrones cognitivos asociados a DCL, enfermedad de Alzheimer y deterioro cognitivo vascular.
- La generación de una estimación probabilística de riesgo presentada como alerta o reporte comprensible para el profesional de la salud.
- La implementación de un módulo de seguimiento longitudinal que permita visualizar la evolución del desempeño cognitivo del usuario.
- La incorporación de actividades básicas de estimulación cognitiva personalizadas según el dominio evaluado.
- La validación técnica del modelo mediante métricas de desempeño y la

validación funcional del prototipo.

5.2. Limitaciones

El proyecto presenta las siguientes limitaciones:

- El sistema no realiza diagnóstico clínico ni sustituye la evaluación de un profesional de la salud; su función es exclusivamente de apoyo y orientación.
- La estimación de riesgo se basa exclusivamente en el análisis estadístico de los datos disponibles en la base utilizada para el entrenamiento del modelo.
- El prototipo no cuenta con certificación como dispositivo médico ni validación clínica formal con pacientes reales.
- La precisión del modelo depende de la calidad, tamaño y balance de la base de datos empleada.
- La estimulación cognitiva implementada tiene carácter complementario y no constituye tratamiento médico.

CAPITULO 6. ANÁLISIS

El análisis tiene como finalidad evaluar la viabilidad del proyecto desde los puntos de vista técnico, económico, operativo, legal y temporal, con el objetivo de determinar si el desarrollo del prototipo es realizable dentro del cronograma propuesto.

6.1. LEVANTAMIENTO DE REQUERIMIENTOS

El presente capítulo documenta los requerimientos del sistema propuesto, resultado del análisis del problema, los objetivos específicos del Trabajo Terminal y las necesidades identificadas en los usuarios potenciales. Los requerimientos se clasifican en dos categorías: requerimientos funcionales, que describen el comportamiento observable del sistema ante las acciones del usuario, y requerimientos no funcionales, que establecen las restricciones de calidad, seguridad, rendimiento y cumplimiento legal bajo las cuales debe operar el sistema.

La especificación de requerimientos se elaboró siguiendo las convenciones del

estándar IEEE 830 para especificación de requerimientos de software, adaptadas al contexto académico del Trabajo Terminal. Cada requerimiento funcional se identifica mediante un código único compuesto por el prefijo 'RF', el identificador del módulo al que pertenece y un número secuencial (por ejemplo, RF-AU-01). Los requerimientos no funcionales siguen el esquema 'RNF-XX'.

Antes de presentar los requerimientos funcionales y no funcionales, se describe la arquitectura tecnológica sobre la que se desarrollará el sistema, dado que esta define las restricciones y posibilidades técnicas del prototipo. El sistema sigue una arquitectura cliente-servidor de tres capas: capa de presentación (aplicación móvil Android), capa de lógica de negocio y modelos de aprendizaje automático (backend en Python), y capa de datos (base de datos relacional y almacenamiento de objetos en la nube de Azure).

En la Tabla 6.1 se presenta el stack tecnológico completo del sistema, con la justificación de cada componente seleccionado.

Capa	Tecnología	Función principal	Justificación
Frontend móvil	**React Native**	Desarrollo de la interfaz de usuario de la aplicación móvil para Android. Permite compartir lógica entre plataformas y mantener un único código base.	Framework multiplataforma con amplia comunidad, compatibilidad con Android 8.0+, y soporte nativo para gráficas, navegación y consumo de API REST.
Backend / API	**Python + FastAPI**	Gestión de la lógica de negocio, autenticación de usuarios, enrutamiento de peticiones y exposición de los modelos de aprendizaje automático como servicios REST.	FastAPI ofrece alto rendimiento, generación automática de documentación (Swagger), tipado estático y soporte asíncrono; ideal para APIs de inferencia de modelos.
Análisis de datos	**NumPy**	Operaciones vectorizadas y matriciales sobre los puntajes por dominio del MoCA y variables sociodemográficas durante el preprocesamiento.	Biblioteca estándar de cómputo numérico en Python; base de scikit-learn y pandas.

Análisis de datos	**pandas**	Carga, limpieza, transformación y análisis exploratorio de la base de datos clínica. Manejo de valores faltantes, codificación de variables y selección de características.	Proporciona estructuras de datos tabulares (DataFrame) optimizadas para datos clínicos heterogéneos.
Aprendizaje automático	**scikit-learn**	Implementación y evaluación de los modelos de clasificación supervisada: Regresión Logística, Máquinas de Vectores de Soporte (MVS) y Bosque Aleatorio (BA). Validación cruzada y métricas de desempeño.	Biblioteca de referencia para aprendizaje automático en Python; integra preprocesamiento, modelado y evaluación en un único ecosistema.
Aprendizaje automático	**imbalanced-learn**	Aplicación de la técnica de Sobremuestreo Sintético de la Clase Minoritaria (SMOTE) para el balanceo de clases diagnósticas en la base de datos de entrenamiento.	Complemento oficial de scikit-learn para el manejo de conjuntos de datos desbalanceados, frecuentes en datos clínicos.
Aprendizaje automático	**SHAP**	Generación de explicaciones interpretables de las predicciones del modelo mediante Valores de Shapley para Explicaciones Aditivas, para la justificación clínica de la estimación de riesgo.	Técnica de inteligencia artificial explicable (IA-X) compatible con todos los modelos de scikit-learn.
Visualización	**Matplotlib / Seaborn**	Generación de gráficas de evolución longitudinal, distribución de puntajes por dominio y curvas de Característica Operativa del Receptor (COR) durante la fase de análisis y validación del modelo.	Bibliotecas estándar de visualización en Python; producen gráficas de calidad para inclusión en reportes técnicos.
Base de datos	**PostgreSQL**	Almacenamiento relacional estructurado de usuarios, perfiles, resultados de evaluaciones, puntajes por dominio y registros de seguimiento longitudinal.	Sistema gestor de base de datos robusto, con soporte para integridad referencial, transacciones ACID y compatibilidad nativa con Azure.
ORM	**SQLAlchemy**	Mapeo objeto-relacional entre los modelos de datos de Python y las tablas de PostgreSQL, facilitando las operaciones de creación, lectura, actualización y eliminación (CRUD).	ORM estándar del ecosistema Python/FastAPI; reduce el código repetitivo y previene inyecciones SQL.
Nube	**Azure App Service**	Despliegue y hospedaje del backend FastAPI como servicio web administrado, con escalabilidad automática y balanceo de carga.	Servicio de plataforma como servicio (PaaS) de Microsoft Azure; elimina la gestión de infraestructura y ofrece integración continua.
Nube	**Azure Database for PostgreSQL**	Hospedaje administrado de la base de datos relacional, con copias de seguridad automáticas, cifrado en reposo y alta disponibilidad.	Servicio administrado que garantiza disponibilidad del 99.99 % y cumplimiento con estándares de seguridad para datos de salud.

Nube	**Azure Blob Storage**	Almacenamiento de archivos binarios: reportes en formato PDF generados por el sistema y modelos de aprendizaje automático serializados.	Almacenamiento de objetos de bajo costo, alta durabilidad y acceso mediante URL segura con firma de acceso compartido (SAS).
Seguridad	**JWT + bcrypt**	Autenticación de usuarios mediante Tokens Web JSON (JWT) con tiempo de expiración configurable. Cifrado de contraseñas con función hash bcrypt y sal aleatoria.	Estándar de autenticación sin estado (stateless) para API REST; bcrypt es el algoritmo recomendado para almacenamiento seguro de contraseñas.
Reportes	**ReportLab**	Generación programática de reportes en formato PDF con puntajes por dominio, gráficas de evolución y estimación de riesgo, para descarga desde la aplicación móvil.	Biblioteca Python de generación de PDF con soporte para gráficas, tablas y texto formateado.

Tabla 6.1. Stack tecnológico del sistema TT 2026-B141 y justificación de cada componente.

La comunicación entre la aplicación móvil y el backend se realiza exclusivamente mediante la interfaz de programación de aplicaciones (API) REST expuesta por FastAPI, utilizando el formato de intercambio de datos JSON (del inglés JavaScript Object Notation, Notación de Objetos de JavaScript). La autenticación en cada petición se realiza mediante un Token Web JSON (JWT) incluido en el encabezado de autorización de cada solicitud HTTP.

6.1.2 Usuarios del sistema y roles

El sistema define dos roles de usuario con acceso diferenciado a las funcionalidades del sistema:

- Paciente: usuario que utiliza la aplicación para realizar evaluaciones cognitivas, consultar su historial de resultados, acceder a actividades de estimulación cognitiva y revisar sus reportes de desempeño. No tiene acceso a los perfiles ni datos de otros usuarios.
- Profesional de Salud: usuario con credenciales verificadas (número de cédula profesional y especialidad) que puede gestionar una lista de pacientes vinculados, visualizar y comparar sus evaluaciones, generar reportes longitudinales y recibir alertas por deterioro significativo en el desempeño de sus pacientes.

Ambos roles comparten el módulo de autenticación y el módulo de evaluación cognitiva. Las vistas de seguimiento longitudinal, gestión de pacientes y generación

de reportes clínicos están disponibles únicamente para el rol Profesional de Salud. Las actividades de estimulación cognitiva están disponibles exclusivamente para el rol Paciente.

6.2 REQUERIMIENTOS FUNCIONALES

Los requerimientos funcionales describen las capacidades y comportamientos que el sistema debe proveer para satisfacer las necesidades de sus usuarios. Se organizan en seis módulos funcionales: Autenticación y Gestión de Acceso, Perfil de Usuario, Evaluación Cognitiva, Motor de Inteligencia Artificial, Seguimiento Longitudinal, Estimulación Cognitiva y Reportes.

6.2.1 Módulo de Autenticación y Gestión de Acceso

Los requerimientos de este módulo definen el mecanismo de acceso al sistema, la gestión de credenciales y el control de roles. Como se observa en la Tabla 3.2, el sistema implementa autenticación propia mediante correo electrónico y contraseña, sin integración con proveedores de identidad externos, garantizando un mecanismo simple, seguro y sin dependencias de terceros.

ID	Nombre	Descripción
RF-AU-01	**Registro de cuenta**	El sistema debe permitir al usuario registrarse proporcionando nombre completo, correo electrónico, contraseña, fecha de nacimiento, sexo y rol

		(paciente o profesional de salud). El correo electrónico debe ser único en el sistema. El profesional de la salud debera tambien añadir su cedula profesional la cual se validara con sus datos para demostrar su real validacion profesional.
RF-AU-02	**Inicio de sesión seguro**	El sistema debe autenticar al usuario mediante correo electrónico y contraseña. Ante credenciales incorrectas debe mostrar un mensaje de error genérico sin revelar cuál campo es incorrecto. Tras cinco intentos fallidos consecutivos debe bloquear el acceso por 15 minutos.
RF-AU-03	**Gestión de Token de Sesión**	El sistema debe emitir un Token Web JSON (JWT) firmado con expiración de 24 horas al autenticar al usuario. El token debe renovarse automáticamente si el usuario está activo y expirar al cerrar sesión.
RF-AU-04	**Recuperación de contraseña**	El sistema debe permitir al usuario solicitar la recuperación de contraseña mediante su correo electrónico registrado, enviando un enlace de restablecimiento.
RF-AU-05	**Cierre de sesión**	El sistema debe permitir al usuario cerrar sesión de forma explícita, invalidando el token activo en el servidor y eliminando los datos de sesión del dispositivo.
RF-AU-06	**Gestión de roles**	El sistema debe diferenciar dos roles: Paciente y Profesional de Salud. Cada rol debe acceder únicamente a las vistas y funcionalidades definidas para su perfil, sin posibilidad de escalar privilegios desde la aplicación.

Tabla 6.2. Requerimientos funcionales del módulo de Autenticación y Gestión de Acceso.

6.2.2 Módulo de Perfil de Usuario

Como se observa en la Tabla 6.3, este módulo gestiona la información personal y profesional de los usuarios, así como la relación entre el profesional de salud y sus pacientes vinculados.

ID	Nombre	Descripción	Prioridad	Módulo
RF-PE-01	**Visualización de perfil**	El sistema debe mostrar al usuario su información de perfil: nombre, correo, fecha de nacimiento, sexo y rol. El profesional de salud debe ver adicionalmente su número de cédula profesional y especialidad.	**Media**	Perfil
RF-PE-02	**Edición de perfil**	El sistema debe permitir al usuario actualizar su nombre (solo rol paciente). El correo electrónico no debe ser editable una vez registrado.	**Media**	Perfil

RF-PE-03	**Gestión de pacientes (profesional)**	El sistema debe permitir al profesional de salud registrar pacientes vinculados a su cuenta, visualizar su listado, acceder a su historial de evaluaciones y reportes, y desvincular pacientes cuando sea necesario.	**Alta**	Perfil
RF-PE-03	**Datos de pacientes (profesional)**	Al registrar los pacientes el profesional, el sistema debera pedir obligatoriamente un expediente medico referente a las areas de intereses del paciente, las cuales son (edad, escolaridad, sexo, enfermedades cardiovasculares, diabetes, enfermedades neurologicas, enfermedades psiquiatricas, coloesterol, historia familiar)	**Alta**	Perfil

Tabla 6.3. Requerimientos funcionales del módulo de Perfil de Usuario.

6.2.3 Módulo de Evaluación Cognitiva

Este módulo constituye el núcleo clínico del sistema. Como se observa en la Tabla 6.4, los requerimientos cubren la implementación digital de los ocho dominios del MoCA, el cálculo automático del puntaje total con la bonificación por escolaridad, la clasificación según puntos de corte establecidos y el almacenamiento estructurado de los resultados.

ID	Nombre	Descripción
RF-EV-01	**Condicion para la realizacion de evaluacion cognitiva**	Para la realizacion de una evaluacion es necesario que el medico este presente, para esto al medico se le generara un codigo unico de autenticacion, el cual el usuario debera ingresar para validar que la esta haciendo con supervicion.
RF-EV-02	**Inicio de evaluación cognitiva**	El sistema debe permitir al usuario o al profesional de salud iniciar una nueva sesión de evaluación cognitiva basada en los ocho dominios del MoCA. Debe registrar automáticamente la fecha, hora y el identificador del evaluador.
RF-EV-03	**Tiempo de evaluacion**	EL sistema no le permitira hacer otra evaluacion MoCA hasta pasado 6 meses, al menos que un profesional la apruebe antes de ese tiempo.

	MoCA	
RF-EV-04		
RF-EV-05	**Evaluación del dominio visuoespacial y ejecutivo**	El sistema debe presentar actividades digitales que evalúen la función visuoespacial y ejecutiva (trazado de camino alternado y copia de figura), capturando el puntaje obtenido en este dominio (máximo 5 puntos).
RF-EV-06	**Evaluación del dominio de denominación**	El sistema debe presentar imágenes de animales para su identificación por parte del usuario, evaluando el acceso léxico y el reconocimiento visual, con puntaje máximo de 3 puntos.
RF-EV-07	**Evaluación del dominio de memoria**	El sistema debe presentar cinco palabras para su registro inmediato y recuerdo diferido tras un intervalo de interferencia, evaluando la memoria episódica verbal (máximo 5 puntos en recuerdo diferido).
RF-EV-08	**Evaluación del dominio de atención**	El sistema debe aplicar tareas de repetición de dígitos en orden directo e inverso, detección de estímulo objetivo y resta seriada de 7, evaluando la atención sostenida y la memoria de trabajo (máximo 6 puntos).
RF-EV-09	**Evaluación del dominio de lenguaje y fluidez verbal**	El sistema debe solicitar al usuario la repetición de frases complejas y la generación de palabras que comiencen con alguna de las letras del abecedario en un minuto, evaluando producción y comprensión lingüística (máximo 3 puntos). La evaluacion sera con validacion manual del medico.
RF-EV-10	**Evaluación del dominio de abstracción**	El sistema debe presentar pares de palabras y solicitar al usuario que identifique la relación conceptual entre ellas, evaluando el razonamiento abstracto (máximo 2 puntos).
RF-EV-11	**Evaluación del dominio de orientación**	El sistema debe solicitar al usuario que identifique la fecha actual, el mes, el año, el día de la semana, el lugar y la ciudad, evaluando la orientación temporoespacial (máximo 6 puntos).
RF-EV-12	**Cálculo automático del puntaje total**	El sistema debe calcular automáticamente el puntaje total sumando los puntajes de los ocho dominios evaluados. Debe aplicar el punto de bonificación por escolaridad cuando el usuario reporte 12 años o menos de educación formal, con un máximo de 30 puntos.
RF-EV-13	**Clasificación según punto de corte**	El sistema debe clasificar automáticamente el puntaje total obtenido según los puntos de corte establecidos: 26–30 puntos (función cognitiva normal), 18–25 puntos (Deterioro Cognitivo Leve), 10–17 puntos (deterioro cognitivo moderado) y menos de 10 puntos (deterioro cognitivo severo probable).
RF-EV-14	**Guardado automático de evaluación**	El sistema debe guardar automáticamente los resultados de cada dominio y el puntaje total al finalizar la evaluación, asociándolos al perfil del usuario y a la fecha de aplicación, sin requerir acción manual del paciente.
RF-EV-15	**Historial de evaluaciones**	El sistema debe mostrar al usuario y al profesional de salud el listado cronológico de todas las evaluaciones realizadas, con fecha, puntaje total y clasificación obtenida en cada sesión.
RF-EV-16	**Problemas de conexion en la evaluacion**	Si el sistema detecta algun fallo de desconexion o interrrupcion con el usuario o profesional, pondra un temporizador de 10 minutos, en caso de que la persona no reanude la conexion en ese tiempo, esta sera cancelada.
RF-EV-17	**Problemas**	En caso de cualquier incoveniente durante la evaluacion el paciente y el

	con el paciente/ profesional	profesional podran cancelar la prueba.
RF-EV-18	**Validacion de respuestas**	El sistema debera validar que las respuestas del usuario sean registradas correctamente antes de avanzar al siguiente ejercicio.
RF-EV-19	**Control del tiempo por seccion**	El sistema debera controlar el tiempo de ejecucion en los dominios que lo requieran.
RF-EV-20	**Integridad de la evaluacion**	El sistema debera asegurarse que todos los dominios sean evaluados antes de calcular el puntaje final.
RF-EV-21	**Bloqueo de evaluacion invalida**	El sistema no almacenara evaluaciones incompletas o canceladas con resultados vacios.
RF-EV-22	**Flujo de la evaluacion**	El sistema debera guiar paso a paso al usarios y al profesional durante la evaluacion, indicando instrucciones claras en cada dominio
RF-EV-23	**Validacion profesional**	El sistema debera permitir al profesional de la salud confirmar o ajustar los resultados en dominios que requieran juicio clinico, como lenguaje.

Tabla 6.4. Requerimientos funcionales del módulo de Evaluación Cognitiva.

6.2.4 Módulo del Motor Predictivo

Como se observa en la Tabla 6.5, este módulo define el comportamiento del componente de estimación probabilística de riesgo cognitivo, incluyendo el preprocesamiento de variables de entrada, la inferencia mediante el modelo supervisado seleccionado, la explicabilidad de la predicción y la exposición del modelo como servicio de la API REST.

ID	Nombre	Descripción
RF-IA-01	**Procesamiento de variables de entrada**	El sistema debe procesar como variables de entrada para el modelo predictivo: el puntaje total del MoCA, los puntajes individuales por dominio, la edad, el sexo y los años de escolaridad del usuario, normalizando y codificando las variables según los requisitos de cada algoritmo.
RF-IA-02	**Clasificación multiclase de riesgo cognitivo**	El sistema debe aplicar el modelo de clasificación supervisada seleccionado (Bosque Aleatorio, Máquinas de Vectores de Soporte o Regresión Logística) para clasificar al usuario en una de las categorías de riesgo: función cognitiva

		normal, Deterioro Cognitivo Leve, probable enfermedad de Alzheimer o probable deterioro cognitivo vascular.
RF-IA-03	**Estimación probabilística por clase**	El sistema debe mostrar la probabilidad estimada de pertenencia a cada categoría de riesgo, expresada en porcentaje, junto con la categoría de mayor probabilidad como resultado principal.
RF-IA-04	**Explicabilidad de la predicción**	El sistema debe mostrar, de forma comprensible para el profesional de salud, los tres dominios cognitivos que más contribuyeron a la estimación de riesgo, utilizando Valores de Shapley para Explicaciones Aditivas (SHAP) como mecanismo de justificación.
RF-IA-05	**Advertencia de carácter no diagnóstico**	El sistema debe mostrar de forma destacada, en toda pantalla que presente resultados del modelo, una advertencia clara indicando que la estimación de riesgo tiene carácter complementario y no sustituye el diagnóstico clínico profesional.
RF-IA-06	**Exposición del modelo como servicio**	El modelo de clasificación supervisada debe estar expuesto como un servicio de la interfaz de programación de aplicaciones (API) REST mediante FastAPI, recibiendo los datos de entrada en formato JSON y devolviendo la clasificación y las probabilidades en el mismo formato.

Tabla 6.5. Requerimientos funcionales del módulo del Motor de Inteligencia Artificial.

6.2.5 Módulo de Seguimiento Longitudinal

Como se observa en la Tabla 6.6, este módulo permite registrar y analizar la evolución del desempeño cognitivo del usuario a lo largo del tiempo, generando visualizaciones comparativas y alertas ante deterioro significativo.

ID	Nombre	Descripción
RF-LO-01	**Visualización de evolución por dominio**	El sistema debe mostrar una gráfica de líneas que represente la evolución del puntaje por dominio cognitivo a lo largo de las evaluaciones registradas, permitiendo identificar tendencias de mejora o deterioro en cada área.
RF-LO-02	**Comparación entre evaluaciones**	El sistema debe permitir al usuario o al profesional de salud seleccionar dos evaluaciones del historial para comparar sus puntajes por dominio de forma visual, mediante una gráfica de barras agrupadas.
RF-LO-03	**Alerta por deterioro significativo**	El sistema debe generar una notificación en la aplicación cuando el puntaje total de una nueva evaluación sea inferior en 3 o más puntos respecto a la evaluación inmediatamente anterior del mismo usuario, indicando los dominios con mayor descenso.

RF-LO-04	**Resumen de progreso**	El sistema debe mostrar al usuario y al profesional de salud un resumen del progreso cognitivo que incluya: número de evaluaciones realizadas, tendencia general del puntaje total, dominio con mejor desempeño y dominio con mayor área de oportunidad.
RF-LO-05	**Exportación de historial**	El sistema debe permitir al profesional de salud exportar el historial longitudinal completo de un paciente como un reporte en formato de documento portátil (PDF), incluyendo todas las evaluaciones, puntajes por dominio y gráficas de evolución.

Tabla 6.6. Requerimientos funcionales del módulo de Seguimiento Longitudinal.

6.2.6 Módulo de Estimulación Cognitiva

Como se observa en la Tabla 6.7, este módulo define las actividades de estimulación cognitiva personalizadas según el perfil de desempeño del usuario, cubriendo los ocho dominios del MoCA con retroalimentación inmediata y registro de progreso.

ID	Nombre	Descripción
RF-ES-01	**Selección de actividades según dominio**	El sistema debe seleccionar y presentar actividades de estimulación cognitiva priorizando los dominios en los que el usuario obtuvo el puntaje más bajo en su última evaluación, garantizando al menos una actividad disponible por cada uno de los ocho dominios del MoCA.
RF-ES-02	**Actividades de estimulación visuoespacial**	El sistema debe ofrecer actividades interactivas que ejerciten la función visuoespacial y ejecutiva, tales como laberintos digitales, secuencias de puntos o ejercicios de trazado guiado.
RF-	**Actividades de**	El sistema debe ofrecer actividades de memoria episódica verbal, como

ES-03	**estimulación de memoria**	juegos de pares de palabras, recordatorio de listas y asociación de palabras con imágenes.
RF-ES-04	**Actividades de estimulación de atención**	El sistema debe ofrecer actividades que ejerciten la atención sostenida y la memoria de trabajo, como secuencias de dígitos, detección de estímulos objetivo y tareas de cancelación visual.
RF-ES-05	**Actividades de estimulación de lenguaje**	El sistema debe ofrecer actividades de fluencia verbal como generación de palabras por categoría semántica o letra inicial, y completar frases con palabras faltantes.
RF-ES-06	**Actividades de estimulación de abstracción y orientación**	El sistema debe ofrecer actividades de razonamiento abstracto (clasificación de objetos por categoría) y orientación temporoespacial (identificación de fecha, lugar y secuencias de eventos).
RF-ES-07	**Retroalimentación inmediata**	Al finalizar cada actividad de estimulación, el sistema debe mostrar al usuario retroalimentación inmediata con el resultado obtenido, el número de respuestas correctas e incorrectas y un mensaje de motivación adaptado al desempeño.
RF-ES-08	**Registro de actividades completadas**	El sistema debe registrar cada actividad de estimulación completada por el usuario, incluyendo el dominio trabajado, la fecha y el resultado obtenido, para su consulta posterior en el historial de actividades.

Tabla 6.7. Requerimientos funcionales del módulo de Estimulación Cognitiva

6.2.7 Módulo de Reportes

Como se observa en la Tabla 6.8, este módulo gestiona la generación, visualización, descarga y almacenamiento en la nube de los reportes de evaluación cognitiva en formato de documento portátil (PDF).

ID	Nombre	Descripción
RF-RE-01	**Generación de reporte por evaluación**	El sistema debe generar un reporte en formato de documento portátil (PDF) para cada evaluación completada, que incluya: datos del usuario, fecha de evaluación, puntajes por dominio, puntaje total, clasificación obtenida, estimación de riesgo con probabilidades por clase y advertencia de carácter no diagnóstico.
RF-RE-02	**Inclusión de gráfica de dominios en reporte**	El reporte generado debe incluir una gráfica de barras con los puntajes obtenidos en cada dominio cognitivo, comparados contra el puntaje máximo posible por dominio.

RF-RE-03	**Inclusión de historial longitudinal en reporte**	El reporte del profesional de salud debe incluir, opcionalmente, la gráfica de evolución longitudinal del paciente con todas las evaluaciones registradas hasta la fecha.
RF-RE-04	**Descarga y compartición de reporte**	El sistema debe permitir al usuario y al profesional de salud descargar el reporte generado en el dispositivo y compartirlo mediante las opciones nativas de Android (correo electrónico, aplicaciones de mensajería, almacenamiento en la nube).
RF-RE-05	**Almacenamiento de reportes en la nube**	El sistema debe almacenar automáticamente cada reporte generado en Azure Blob Storage, disponible para su consulta o descarga posterior desde la aplicación durante un período mínimo de 12 meses.

Tabla 6.8. Requerimientos funcionales del módulo de Reportes.

6.3 REQUERIMIENTOS NO FUNCIONALES

Los requerimientos no funcionales establecen las restricciones de calidad, seguridad, rendimiento, usabilidad, disponibilidad, mantenibilidad, portabilidad y cumplimiento legal bajo las cuales debe operar el sistema. A diferencia de los requerimientos funcionales, no describen qué hace el sistema, sino cómo debe hacerlo. Cada requerimiento incluye una métrica de cumplimiento verificable que permitirá evaluar objetivamente su satisfacción durante la fase de pruebas del prototipo.

Como se observa en la Tabla 3.9, los requerimientos no funcionales se organizan en siete categorías: Rendimiento, Seguridad, Usabilidad, Disponibilidad, Mantenibilidad, Portabilidad, y Legal y Ético.

ID	Categoría	Descripción	Métrica de cumplimiento
RNF-01	**Rendimiento — Tiempo de**	El servicio de estimación de riesgo expuesto por la API REST debe responder en un	Tiempo de respuesta ≤ 3 s medido con la herramienta

	respuesta de la API	tiempo máximo de 3 segundos bajo condiciones normales de operación con una carga de hasta 50 peticiones concurrentes.	Locust bajo carga de 50 usuarios concurrentes.
RNF-02	**Rendimiento — Carga de pantallas**	Cada pantalla de la aplicación móvil debe renderizarse completamente en un tiempo máximo de 2 segundos en dispositivos Android con conexión a red de tipo 4G o superior.	Tiempo de carga ≤ 2 s verificado con React Native Performance Monitor en dispositivo físico con Android 10.
RNF-03	**Rendimiento — Precisión del modelo**	El modelo de clasificación supervisada seleccionado debe alcanzar una puntuación F1 mínima de 0.80 y un área bajo la curva de Característica Operativa del Receptor (AUC-COR) mínima de 0.85 en el conjunto de prueba.	F1 ≥ 0.80 y AUC-COR ≥ 0.85 reportados en la matriz de confusión y curva COR generadas con scikit-learn.
RNF-04	**Seguridad — Cifrado de comunicaciones**	Toda comunicación entre la aplicación móvil y el servidor backend debe realizarse mediante el protocolo HTTPS con certificado TLS 1.2 o superior, garantizando la confidencialidad e integridad de los datos transmitidos.	100 % de las peticiones realizadas sobre HTTPS, verificado con análisis de tráfico en Postman y Azure Application Gateway.
RNF-05	**Seguridad — Almacenamiento de contraseñas**	Las contraseñas de los usuarios deben almacenarse en la base de datos exclusivamente como hash generado con la función bcrypt con factor de costo mínimo de 12, sin almacenarse en texto claro en ningún componente del sistema.	Verificación directa en base de datos: ningún registro contiene contraseña en texto claro; todos los hashes inician con '$2b$12$'.
RNF-06	**Seguridad — Control de acceso por rol**	El sistema debe garantizar que un usuario con rol Paciente no pueda acceder a los datos ni a las vistas correspondientes al rol Profesional de Salud, y viceversa, validando el rol en cada petición a través del token JWT en el servidor.	Pruebas de intento de acceso cruzado entre roles: el servidor debe responder con código HTTP 403 en el 100 % de los casos.
RNF-07	**Seguridad — Anonimización de datos para el modelo**	Los datos procesados por el motor de clasificación supervisada no deben incluir información de identificación personal directa (nombre, correo electrónico). Solo se transmiten al modelo variables clínicas y sociodemográficas numéricas.	Verificación en el código del servicio de inferencia: los objetos JSON enviados al modelo no contienen campos de identificación personal.
RNF-08	**Seguridad — Protección contra inyección**	El sistema debe prevenir ataques de inyección de Lenguaje de Consulta Estructurado (SQL) mediante el uso exclusivo del mapeador objeto-relacional SQLAlchemy con consultas parametrizadas, sin construcción de cadenas SQL dinámicas.	Pruebas de inyección SQL con la herramienta SQLMap: ninguna consulta vulnerable en los endpoints de la API.
RNF-09	**Usabilidad — Accesibilidad para adultos mayores**	La interfaz de usuario debe utilizar un tamaño mínimo de fuente de 16 sp, botones con área táctil mínima de 48 × 48 dp, contraste de color mínimo de 4.5:1 según las Pautas de Accesibilidad para el Contenido Web (WCAG) 2.1 nivel AA, e instrucciones	Auditoría con la herramienta Accessibility Scanner de Android: cero advertencias de tamaño de texto o contraste insuficiente.

		textuales en lenguaje simple.	
RNF-10	**Usabilidad — Instrucciones contextuales**	Cada pantalla de evaluación cognitiva debe incluir instrucciones claras y visibles antes de iniciar la tarea correspondiente, con opción de releer las instrucciones en cualquier momento durante la actividad.	Verificación manual: todas las pantallas de evaluación muestran botón de ayuda funcional; pruebas con usuarios simulados.
RNF-11	**Usabilidad — Retroalimentación de estado**	La aplicación debe mostrar indicadores visuales de progreso (barra de avance o número de dominio actual) durante la evaluación cognitiva, y confirmaciones visuales ante cada acción del usuario que implique guardado o envío de datos.	Revisión de diseño: todas las pantallas de evaluación incluyen indicador de progreso; prueba de cada acción de guardado.
RNF-12	**Disponibilidad — Operación básica sin conexión**	La aplicación móvil debe permitir al usuario consultar su historial de evaluaciones y acceder a las actividades de estimulación cognitiva previamente descargadas en modo sin conexión, sincronizando los datos con el servidor al restablecer la conectividad.	Prueba de desconexión de red durante uso: historial y actividades accesibles; datos sincronizados al reconectar en menos de 30 s.
RNF-13	**Disponibilidad — Uptime del servicio en la nube**	El backend desplegado en Azure App Service debe mantener una disponibilidad mínima del 99 % mensual, aprovechando las garantías del Acuerdo de Nivel de Servicio (ANS) de Microsoft Azure para App Service.	Monitoreo con Azure Monitor: disponibilidad mensual reportada ≥ 99 % durante el período de evaluación del prototipo.
RNF-14	**Mantenibilidad — Arquitectura modular**	El backend debe estar organizado en módulos independientes por funcionalidad (autenticación, evaluación, modelo de IA, reportes, seguimiento), de modo que la modificación de un módulo no afecte el funcionamiento de los demás.	Revisión de arquitectura: cada módulo tiene su propio enrutador FastAPI y carpeta de código fuente; sin dependencias circulares.
RNF-15	**Mantenibilidad — Documentación de la API**	La API REST debe contar con documentación generada automáticamente por FastAPI (Swagger UI / ReDoc), accesible en el entorno de desarrollo, que describa todos los endpoints, parámetros de entrada, respuestas y códigos de error.	Verificación en entorno de desarrollo: documentación Swagger accesible en /docs; todos los endpoints documentados con esquemas de entrada y salida.
RNF-16	**Portabilidad — Compatibilidad con Android**	La aplicación móvil debe ser compatible con dispositivos Android con versión mínima del sistema operativo 8.0 (nivel de API 26) y superiores, cubriendo al menos el 90 % de los dispositivos Android activos en México según las estadísticas de distribución de Android.	Pruebas en emulador y dispositivo físico con Android 8.0, 10 y 13: la aplicación instala, inicia y opera correctamente en todas las versiones.
RNF-17	**Portabilidad — Independencia del entorno de despliegue**	El backend debe estar contenerizado mediante Docker, de modo que pueda desplegarse en cualquier entorno compatible con contenedores (Azure App Service, máquina virtual, entorno local) sin modificaciones al código fuente.	El contenedor Docker construido a partir del Dockerfile del proyecto ejecuta correctamente el servidor FastAPI en entorno local y en Azure App Service.

RNF-18	**Legal — Protección de datos personales**	El sistema debe cumplir con los principios de la Ley Federal de Protección de Datos Personales en Posesión de los Particulares (LFPDPPP): licitud, consentimiento, información, calidad, finalidad, lealtad, proporcionalidad y responsabilidad. Los datos del usuario deben utilizarse exclusivamente para los fines declarados en el aviso de privacidad del sistema.	Revisión jurídica del aviso de privacidad integrado en la aplicación; verificación de que no se comparten datos con terceros no declarados.
RNF-19	**Ético — Consentimiento informado**	Al registrarse, el usuario debe leer y aceptar explícitamente el aviso de privacidad y los términos de uso del sistema, incluyendo la naturaleza complementaria y no diagnóstica de los resultados. El sistema no debe permitir el registro sin esta aceptación.	Verificación en flujo de registro: la casilla de aceptación es obligatoria; sin su marcado, el botón de registro permanece deshabilitado.
RNF-20	**Ético — Advertencia permanente sobre carácter no diagnóstico**	En toda pantalla que presente resultados de la estimación de riesgo, el sistema debe mostrar de forma permanente y visible una leyenda que indique que el resultado es una estimación probabilística de apoyo y no un diagnóstico médico.	Revisión visual de todas las pantallas de resultados: leyenda de advertencia visible sin necesidad de desplazamiento (scroll).

Tabla 6.9. Requerimientos no funcionales del sistema TT 2026-B141.

6.4. ANÁLISIS DE FACTIBILIDAD

6.4.1 Factibilidad operativa

La factibilidad operativa evalúa si el sistema puede funcionar de manera efectiva en el entorno real donde será utilizado, considerando los perfiles de usuarios, las condiciones de acceso tecnológico y la integración con los flujos de trabajo existentes.

Usuarios del sistema y escenarios de uso

El sistema está diseñado para ser utilizado por cuatro perfiles de usuario claramente diferenciados, cada uno con un rol específico dentro del flujo de evaluación cognitiva:

Perfil de usuario	Rol en el sistema	Frecuencia de uso estimada
Médico general / geriatra	Aplica la evaluación MoCA digital durante consulta y revisa el reporte de riesgo generado	5–15 evaluaciones por día

Neurólogo / neuropsicólogo	Consulta el reporte probabilístico con valores SHAP como apoyo al diagnóstico diferencial	2–8 reportes por día
Familiar o cuidador	Realiza seguimiento preventivo del adulto mayor en el hogar	Mensual
Adulto mayor (paciente)	Ejecuta actividades de estimulación cognitiva personalizadas	Diaria o semanal

Tabla 6.10. Factibilidad operativa

La viabilidad operativa del sistema está respaldada por datos estadísticos actualizados sobre el acceso a tecnología en México. La ENDUTIH 2023 estimó que en México había 97 millones de personas usuarias de internet, lo que representó el 81.2% de la población de 6 años o más. En cuanto al dispositivo de acceso, para 2023 se estimó que el 95.5% de las personas usuarias de teléfono celular solo utilizaba smartphone. Este dato confirma que la elección de Android como plataforma de despliegue es pertinente para alcanzar a la población objetivo del sistema. [24]

Sin embargo, la brecha digital en adultos mayores representa un riesgo operativo que debe gestionarse en el diseño de la interfaz. Entre 2022 y 2023, el grupo con mayor incremento en uso de internet fue el de 55 a 64 años, que aumentó 6.9 puntos porcentuales. Este crecimiento acelerado en el segmento de mayor edad refuerza la pertinencia del sistema, aunque implica la necesidad de una interfaz accesible con instrucciones claras y tipografía de tamaño adecuado, conforme a los principios de usabilidad de Nielsen para aplicaciones mHealth dirigidas a adultos mayores.

Condiciones operativas del sistema

Aspecto	Evaluación
Compatibilidad Android	React Native 0.84 soporta Android 6.0 (API nivel 23) como mínimo [A]
Conectividad requerida	Conexión a internet para sincronización con backend en Azure; evaluaciones en modo offline con sincronización posterior
Capacitación necesaria	Mínima — interfaz orientada a usuarios no técnicos
Integración en entorno clínico	Complementaria — no modifica los flujos de trabajo existentes
Disponibilidad del servicio	Azure App Service Basic B1 ofrece SLA del 99.95% [B]

Tabla 6.11. Condiciones operativas del sistema

El sistema es operativamente viable como herramienta de apoyo a la detección temprana, siempre bajo supervisión profesional y con las advertencias explícitas sobre su carácter complementario al diagnóstico clínico.

6.4.2. Factibilidad tecnológica.

La factibilidad tecnológica analiza la disponibilidad, madurez y compatibilidad de las herramientas, frameworks, librerías y servicios en la nube seleccionados para el desarrollo del sistema.

Frontend móvil — React Native 0.84

React Native 0.84, lanzado el 11 de febrero de 2026, hace de Hermes V1 el motor de JavaScript predeterminado, lo que aporta mejoras significativas de rendimiento a todas las aplicaciones React Native. La versión 0.84.x se encuentra actualmente en estado Active de soporte. Su elección se justifica por la posibilidad de desarrollar una aplicación Android nativa con un único código base, reutilizando la lógica de componentes y reduciendo los tiempos de desarrollo frente a un desarrollo nativo puro en Kotlin. [25]

Librería React Native	Versión	Uso en el proyecto
`react-navigation`	7.x	Navegación entre

		pantallas: evaluación, historial, reportes
react-native-chart-kit	6.x	Gráficas de seguimiento longitudinal del desempeño cognitivo
axios	1.7.x	Comunicación HTTP con la API FastAPI alojada en Azure
react-hook-form	7.x	Gestión y validación de formularios del módulo MoCA digital
react-native-async-storage	2.x	Almacenamiento local de sesión y caché offline de resultados
expo-notifications	0.29.x	Recordatorios de evaluaciones periódicas al usuario

Tabla 6.12. Versiones de React Native [26]

Backend — Python 3.12 + FastAPI

FastAPI es un framework web moderno de alto rendimiento para construir APIs con Python, con una velocidad comparable a NodeJS y Go, que reduce en aproximadamente un 40% los errores inducidos por desarrolladores gracias a su sistema de tipos. Internamente, FastAPI CLI utiliza Uvicorn, un servidor ASGI de alto rendimiento y listo para producción. FastAPI se encarga de gestionar todas las rutas de la API REST, la autenticación de usuarios mediante tokens JWT, la comunicación con el modelo de ML serializado y la generación de reportes PDF para el profesional de salud. [27]

Las librerías Python del proyecto y su rol específico son:

Librería	Versión estable	Rol en el proyecto
fastapi + uvicorn	0.115.x / 0.32.x	Framework API REST y servidor ASGI de producción
pydantic	2.x	Validación de esquemas de entrada/salida (puntajes MoCA, reportes)
pandas	3.0.x [C]	Carga, limpieza y

		manipulación del dataset clínico por columnas de dominios MoCA
numpy	2.4.x [C]	Operaciones matriciales, normalización Z-score y Min-Max sobre vectores de características
scikit-learn	1.8.0 [D]	Implementación de Regresión Logística, SVM y Random Forest; validación cruzada k-fold y métricas AUC
imbalanced-learn	0.12.x	Aplicación de SMOTE para balanceo de clases (DCL, Alzheimer, DCV)
shap	0.46.x	Generación de valores SHAP para aplicabilidad XAI del modelo en los reportes clínicos
matplotlib / seaborn	3.10.x / 0.13.x	Gráficas de curva ROC, matriz de confusión e importancia de características
sqlalchemy + alembic	2.0.x / 1.13.x	ORM para PostgreSQL y control de migraciones del esquema relacional
python-jose + passlib	3.x / 1.7.x	Autenticación JWT y hash seguro de contraseñas (bcrypt)
reportlab	4.x	Generación de reportes PDF con estimación de riesgo para el médico

Tabla 6.13. librerías de Python [28]

Base de datos — PostgreSQL 17 (Azure Database for PostgreSQL Flexible Server)

Se utilizará un modelo de datos relacional para almacenar las entidades del sistema: usuarios, evaluaciones MoCA, puntajes por dominio cognitivo, historial longitudinal y estimaciones de riesgo. La elección de PostgreSQL sobre alternativas NoSQL se fundamenta en la naturaleza estructurada de los datos clínicos, que requieren integridad referencial, consultas analíticas sobre series temporales por paciente y soporte para transacciones ACID. [29]

Servicios Microsoft Azure

Servicio	Nivel utilizado	Función en el proyecto
Azure App Service (Linux)	Free F1 (TT1) → Basic B1 (TT2)	Despliegue del backend FastAPI con uvicorn
Azure Database for PostgreSQL Flexible Server	Burstable B1ms	Instancia administrada de la base de datos relacional

Azure Blob Storage	Hot tier	Almacenamiento de reportes PDF generados por reportlab

Tabla 6.14. Servicios de Microsoft Azure [30][31][32]

Complejidad técnica por componente

Componente	Nivel de complejidad	Justificación
App React Native (Android)	Media	UI con navegación, formularios MoCA, gráficas de seguimiento
API REST con FastAPI	Media	Rutas CRUD, autenticación JWT, llamada al modelo serializado
Modelo ML (scikit-learn)	Media–Alta	Ajuste de hiperparámetros, validación cruzada k-fold, métricas AUC
Integración Azure App Service	Baja–Media	Despliegue con uvicorn en contenedor Linux administrado
Base de datos PostgreSQL en Azure	Media	Esquema relacional normalizado, migraciones con Alembic
Generación reportes PDF	Media	reportlab + valores SHAP, entrega vía Azure Blob Storage
Seguimiento longitudinal	Media	Consultas temporales sobre historial de evaluaciones en PostgreSQL

Tabla 6.15. Complejidad técnica por componente [33]

6.4.3. Factibilidad económica.

Estructura de costos en contexto profesional

Si el proyecto se desarrollara en un entorno comercial o de startup de salud digital, el costo estimado sería:

Concepto	Costo Estimado (MXN)	Observaciones
Equipo de desarrollo (8 personas × 10 meses)	$2,900,000 – $4,580,000	Salarios del mercado
Licencias de software	$0	Stack 100% open source
Infraestructura cloud (GCP/AWS)	$12,000 – $24,000/año	Instancias pequeñas para prototipo
Asesor clínico (honorarios)	$120,000 – $240,000	12 meses, dedicación parcial
Pruebas con usuarios reales (piloto)	$60,000 – $120,000	Reclutamiento, logística
Certificación como	$150,000 – $500,000	Solo si se comercializa

dispositivo médico (COFEPRIS)		
Total estimado (comercial)	**$3,242,000 – $5,464,000**	Prototipo funcional validado
Costo académico (TT 2026-B141)	**$0 MXN**	Recursos propios + IPN

Tabla 6.16. Estructura de costos [34][35][36]

Modelo de escalabilidad económica

Conforme el proyecto avanza en fases, los costos y recursos se multiplican de manera predecible. Esta es la curva de crecimiento real documentada en proyectos en América Latina:

Fase	Periodo	Personal Activo	Costo Acumulado Est. (MXN)	Hito Clave
Fase 0 — **Análisis y diseño**	Feb – Abr 2026	3 personas	$0 (académico)	Requerimientos, arquitectura
Fase 1 — **Desarrollo del modelo ML**	May – Jun 2026	3 personas	$0 (académico)	Evaluación TT1, modelo entrenado
Fase 2 — **Desarrollo del sistema**	Ago – Oct 2026	3–4 personas	$0 (académico)	API + App funcional

Fase 3 — **Validación y pruebas**	Nov – Dic 2026	4–5 personas	$0 (académico)	Evaluación TT2, métricas de desempeño
Fase 4 — **Piloto clínico (post-TT)**	2027	5–7 personas	~$800,000 – $1,200,000	Validación con pacientes reales

Tabla 6.17. Modelo de escalabilidad económica [37]

La multiplicación de personal se da entre Fase 3 y Fase 4, cuando se requiere incorporar al asesor clínico de tiempo completo, un abogado especialista en datos de salud, un DevOps/Seguridad y al menos dos testers adicionales.

Equipo de desarrollo requerido

Para un proyecto de esta naturaleza (sistema mHealth + modelo predictivo + backend clínico), la literatura sobre ingeniería de software en salud recomienda los siguientes perfiles:

#	Rol	Salario Mensual Est. (MXN)
1	Líder de Proyecto / Scrum Master	$35,000 – $50,000
2	Científico de Datos / ML Engineer	$32,000 – $68,000
3	Desarrollador Backend (Python/FastAPI)	$18,000 – $43,000
4	Desarrollador Móvil (Flutter)	$16,000 – $40,000
5	Ingeniero de Base de Datos	$20,000 – $45,000
6	Especialista UX/UI para mHealth	$16,000 – $35,000
7	Asesor Clínico	$50,000 – $80,000

	(Neurólogo/Geriatra)	
8	Tester / QA Engineer	$16,000 – $30,000

Tabla 6.18. Equipo de desarrollo [38][39][40][41][42][43]

Nota para el TT 2026-141: En el contexto académico, los tres integrantes del equipo absorben colectivamente los roles 2 al 5. El rol 1 es cubierto por la Lic. Palacios Solano Rocio y el rol 7 por la Dr.... y las consultas con profesionales. El costo monetario directo es $0 MXN.

Áreas organizacionales del proyecto

El sistema se organiza en cuatro áreas funcionales que interactúan entre sí:

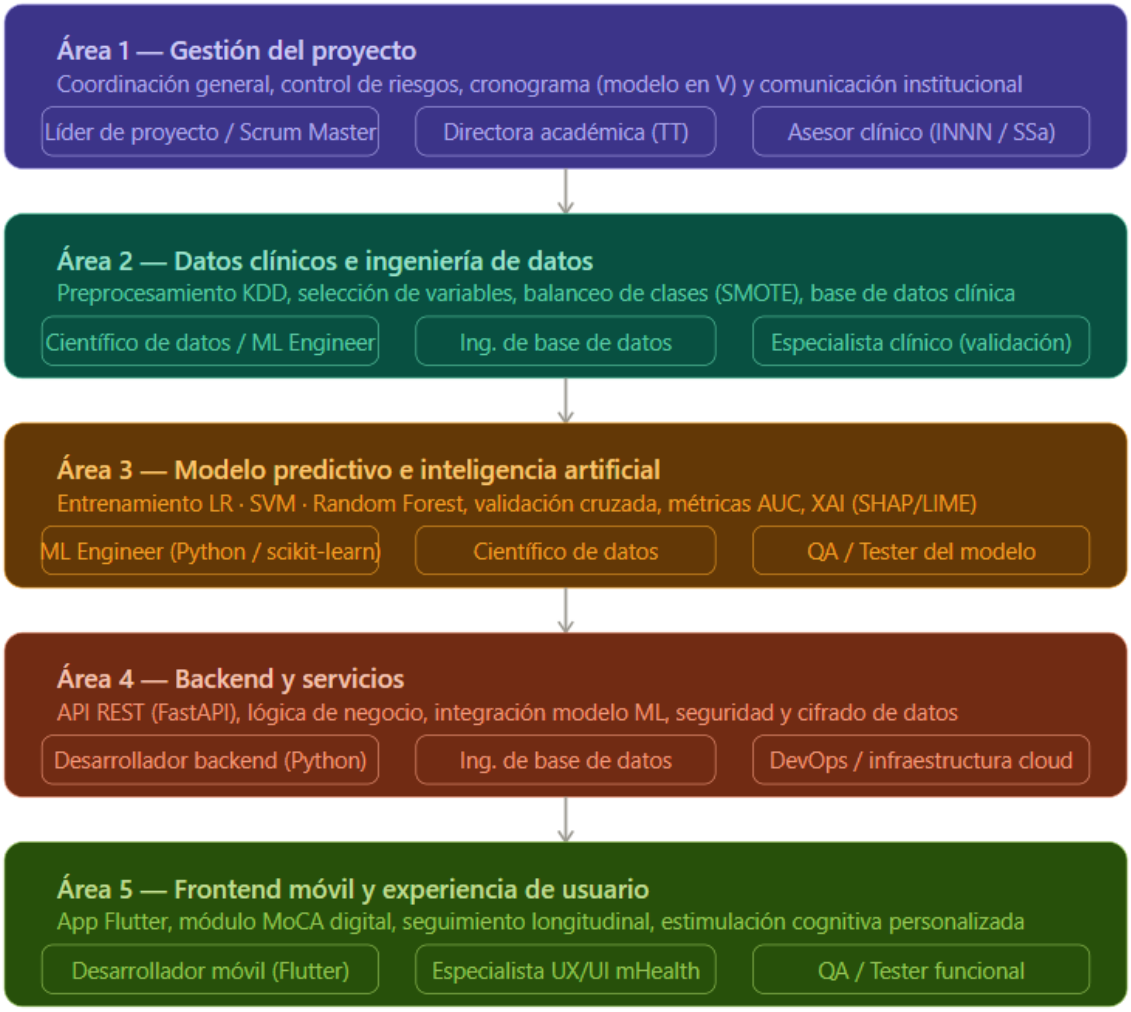


Imagen 6.19. Áreas organizacionales. [44]

Nota: En TT 2026-B141 los roles de Áreas 2–5 son absorbidos por los 3 integrantes del equipo. El Área 1 es apoyada por la Dra… y asesores del INNN

6.4.4. Factibilidad legal y ética

Marco Normativo Aplicable en México

Norma / Ley	Aplicación al Proyecto
Ley Federal de Protección de Datos Personales en Posesión de los Particulares (LFPDPPP, 2010)	Anonimización y cifrado de datos de usuarios
NOM-024-SSA3-2012	Sistemas de información de registro electrónico para la salud
Ley General de Salud — Art. 100	Investigación con seres humanos, consentimiento informado
COFEPRIS — Dispositivos Médicos (solo en fase comercial)	No aplica en prototipo académico
Reglamento IPN sobre Propiedad Intelectual	El prototipo es propiedad del IPN como institución

Tabla 6.20. Marco normativo en México [45][46][47]

Riesgos normativos y estrategias de mitigación

Riesgo identificado	*Estrategia de mitigación*
Interpretación errónea de, resultado por parte del usuario	*Incluir advertencias claras y contextualización del resultado en la interfaz*
Uso sin supervisión médica adecuada	*Establecer y comunicar explícitamente el carácter complementario del sistema*
Manejo inadecaudo de los datos personales	*Implementar medidas de seguridad, anonimización y cifrado de datos*

Tabla 6.21. Riesgos éticos y estrategias de mitigación.

6.4.5. Factibilidad temporal

El proyecto se desarrollará a lo largo de dos semestres (TT1 y TT2), siguiendo la metodología en V, que estructura el trabajo en fases secuenciales con su correspondiente etapa de validación. Las actividades principales se distribuyen de la siguiente manera:

ACTIVIDAD	FEB	MAR	ABR	MAY	JUN	JUL	AGO	SEP	OCT	NOV	DIC
Análisis y definición del problema	■										
Estudio de las enfermedades neurodegenerativas		■	■								
Levantamiento de requerimientos del sistema		■									
Diseño de interfaz de usuario				■							
Diseño de la arquitectura del sistema											
Diseño del modelo de base de datos			■								
Diseño de los módulos del sistema				■							
Evaluación TT1				■		■					
Preparación de base de datos (Recolección de datos)	■	■	■	■	■	■	■	■	■	■	■
Minería de datos y procesamiento						■	■				
Formulación de modelos de predicción y algoritmos								■	■		
Revisión de consistencia entre requerimientos y diseño						■	■	■			
Codificación de la aplicación					■	■	■				
Pruebas unitarias										■	
Pruebas de integración										■	
Pruebas de sistema										■	
Validación de resultados obtenidos											■
Pruebas de aceptación											
Elaboración de reporte técnico Final											■
Evaluación de TT2											■
Elaboración de reporte técnico	■	■	■	■	■	■	■	■	■	■	■

Tabla 6.22 Cronograma de actividades — TT1 (Feb–Jun 2026) y TT2 (Ago–Dic 2026). Celdas sombreadas = periodo activo. Evaluación TT1: mayo–junio. Evaluación TT2: diciembre.

El cronograma es factible dentro del periodo establecido para el Trabajo Terminal, dado el enfoque modular del sistema y el uso de herramientas de libre acceso.

Conclusión General de Factibilidad. El proyecto es económicamente viable dentro del marco académico del IPN. El costo total de la fase TT1–TT2 no supera los **$2,417 MXN** en infraestructura Azure, siendo el único egreso real el servicio de base de datos PostgreSQL y, a partir de TT2, el plan Basic B1 de App Service. El stack tecnológico completo opera bajo licencias de código abierto con costo de adquisición de $0 MXN.

CAPITULO 7. DISEÑO DEL SISTEMA

REFERENCIAS

[1] World Health Organization, Dementia fact sheet. [En línea]. Disponible en: https://www.who.int/news-room/fact-sheets/detail/dementia. Consultado: 2025.

[2] Secretaría de Salud, "Alzheimer, demencia más frecuente en personas mayores a 65 años," Boletín informativo, 21 de septiembre de 2023. [En línea]. Disponible en: https://www.gob.mx/salud/prensa/301-alzheimer.

[3] L. M. Gutiérrez-Robledo e I. Arrieta-Cruz, "Enfermedad de Alzheimer y otras demencias como problema nacional de salud," Documento de posición del Instituto Nacional de Geriatría, México: InGer, 2015.

[4] Instituto Nacional de Geriatría, Plan Nacional de Demencia México 2024. México: Secretaría de Salud / InGer, 2024.

[5] A. I. García Caballero, "Evaluación y diagnóstico del deterioro cognitivo leve," Revista de Logopedia, Foniatría y Audiología, vol. 32, núm. 2, pp. 47–56, 2012.

[6] A. de la Torre y A. Sánchez-Cabaco, "Detección temprana de deterioro cognitivo leve en personas mayores durante la pandemia: protocolo de cribado online," Revista Chilena de Neuro-Psiquiatría, vol. 60, núm. 4, pp. 403–415, 2022.

[7] Z. S. Nasreddine et al., "The Montreal Cognitive Assessment (MoCA): a brief screening tool for mild cognitive impairment," Journal of the American Geriatrics Society, vol. 53, núm. 4, pp. 695–699, 2005.

[8] C. Loureiro et al., "Uso del test de evaluación cognitiva de Montreal (MoCA) en América Latina: revisión sistemática," Revista de Neurología, vol. 66, pp. 397–408, 2018.

[9] J. Sánchez y V. Mendoza, "Prevalencia de probable deterioro cognitivo en adultos mayores de una población mexicana utilizando el MMSE y el MoCA," Gerokomos, vol. 32, núm. 3, pp. 168–174, 2021.

[10] J. P. Palacios Garay, "Deterioro cognitivo en la adultez tardía, dimensiones y afectaciones asociados," Revista Vive, 2025. https://doi.org/10.33996/revistavive.v8i22.563

[11] P. García Soidan et al., "Prevalencia de deterioro cognitivo en España. Estudio Gómez de Caso en redes centinelas sanitarias," Neurología, vol. 33, núm. 8, pp. 491–498, 2018.

[12] A. Seubert Ravelo, "Alzheimer, enfermedad neurodegenerativa más común en el mundo," Boletín UNAM-DGCS, núm. 709, septiembre 2023.

[13] Medical Impact, "Impacto de las demencias en la salud pública mexicana: Proyecciones y desafíos para 2030," 2023.

[14] M. Bucholc et al., "A hybrid machine learning approach for prediction of conversion from mild cognitive impairment to dementia," Expert Systems with Applications, vol. 217, p. 119541, 2023.

[15] V. Vimbi et al., "Random Forest and SVM classifiers using MRI data combined with cognitive scores," citado en: A. A. Al-Faris et al., PMC, 2024.

[16] Y. Wang et al., "Interpretable machine learning-driven biomarker identification and risk prediction for Alzheimer's disease," PMC, 2024.

[17] A. S. Alatrany et al., "An explainable machine learning approach for Alzheimer's disease classification," Scientific Reports, 2024. https://doi.org/10.1038/s41598-024-51985-w

[18] F. Tascedda et al., "Advanced AI techniques for classifying Alzheimer's disease and mild cognitive impairment," Frontiers in Aging Neuroscience, vol. 16, 2024. https://doi.org/10.3389/fnagi.2024.1492506

[19] Lumos Labs Inc., Lumosity – Brain Training. [En línea]. Disponible en: https://www.lumosity.com/

[20] CogniFit Inc., CogniFit Cognitive Training. [En línea]. Disponible en: https://www.cognifit.com/

[21] Alzheimer's Disease International, World Alzheimer Report 2015: The Global Impact of Dementia. Londres: ADI, 2015. Trabajo Terminal 2026-B141 — ESCOM / IPN Sistema Prototipo de Detección de Enfermedades Neurodegenerativas pág. 27

[22] P. Canevelli et al., "Living with dementia: The needs of patients and caregivers," International Journal of Environmental Research and Public Health, vol. 17, núm. 8, p. 2975, 2020.

[23] S. Munshi, "Free and open-source software in health care: A review," Health Information Science and Systems, vol. 7, núm. 1, 2019.

[24] Instituto Nacional de Estadística y Geografía. (2024, 13 de junio). Encuesta Nacional sobre Disponibilidad y Uso de Tecnologías de la Información en los Hogares (ENDUTIH) 2023 (Comunicado de prensa núm. 372/24). INEGI / Instituto Federal de Telecomunicaciones.

[25] Hunt, A., Lee, A., Falch, C., y Donadel Dall'Agnol, G. (2026, 11 de febrero). React Native 0.84 — Hermes V1 by Default. Meta Platforms / React Native Blog. https://reactnative.dev/blog/2026/02/11/react-native-0.84

[26] Meta Platforms. (2026). React Native releases: version support schedule. React Native. https://reactnative.dev/versions

[27] Ramírez, S. (2026). FastAPI: framework web moderno de alto rendimiento para construir APIs con Python (documentación oficial). Tiangolo. https://fastapi.tiangolo.com

[28] Ramírez, S. (2026). *About FastAPI versions*. Tiangolo. https://fastapi.tiangolo.com/deployment/versions/

[29] The PostgreSQL Global Development Group. (2026). PostgreSQL 17 documentation. https://www.postgresql.org/docs/17/

[30] Microsoft Azure. (2026). *Azure App Service — overview of plans and capabilities*. Consultado el 25 de marzo de 2026. https://azure.microsoft.com/en-us/products/app-service

[31] Microsoft Azure. (2026). *Azure Database for PostgreSQL Flexible Server — pricing*. Consultado el 25 de marzo de 2026. https://azure.microsoft.com/en-us/pricing/details/postgresql/flexible-server/

[32] Microsoft Azure. (2026). *Azure Blob Storage pricing*. Consultado el 25 de marzo de 2026. https://azure.microsoft.com/en-us/pricing/details/storage/blobs/

[33] Sommerville, I. (2016). *Ingeniería del software* (10.ª ed.). Pearson Educación. ISBN 978-0-13-394303-0

[34] Grupo Milenio / Banco de México (Banxico). (2026, 24 de marzo). Tipo de cambio FIX determinado el 24/03/2026: $17.8047 MXN por dólar. https://www.milenio.com/negocios/precio-del-dolar-hoy-24-marzo-2026-a-cuanto-cotiza-en-vivo-atm

[35] Peiris, D., Praveen, D., Johnson, C., Miranda, J. J., Raj, T. S., Pearce, G., Mogulluru, K., Raghu, A., Li, Q., Vaughan, M., Holbrook, N., Bayiga, E., y Rodgers, A. (2019). The SMART health systems programme: a cost-effectiveness analysis. The Lancet Digital Health, 1(6), e258–e268. https://doi.org/10.1016/S2589-7500(19)30116-7

[36] Bobur, U. (2025, 12 de febrero). Cost comparison: Neon vs. Azure Database for PostgreSQL Flexible Server. DEV Community. https://dev.to/bobur/cost-comparison-neon-vs-azure-database-for-postgresql-flexible-server-2lpp

[37] Curiel, R. E., Tsiouris, J. A., Patel, V., Sathian, B., Bhatt, P., Mehta, H., y Ritchfield, I. (2020). Novel technology for the assessment of cognitive function in Alzheimer's disease and mild cognitive impairment. Journal of the American Medical Directors Association (JAMDA), 21(5), 641–646. https://doi.org/10.1016/j.jamda.2019.11.027

[38] Indeed México. (2026, 22 de febrero). *Sueldo de desarrollador/a de software en México* (4,900 sueldos reportados). Indeed. https://mx.indeed.com/career/desarrollador-de-software/salaries

[39] Indeed México. (2026, 5 de marzo). *Sueldo de Data Scientist en México* (93 sueldos reportados). Indeed. https://mx.indeed.com/career/data-scientist/salaries

[40] Glassdoor México. (2026, marzo). *Sueldo: Software Developer en México* (3,591 sueldos reportados anónimamente). Glassdoor. https://www.glassdoor.com.mx/Sueldos/software-developer-sueldo-SRCH_KO0,18.htm

[41] Glassdoor México. (2026, febrero). *Sueldo: Machine Learning Engineer en México* (69 sueldos reportados anónimamente). Glassdoor. https://www.glassdoor.com.mx/Sueldos/machine-learning-engineer-sueldo-SRCH_KO0,25.htm

[42] Coderhouse México. (2026). *Sueldo Data Scientist en México 2026*. https://www.coderhouse.com/mx/sueldos/sueldo-data-scientist-mexico-2025

[43] Secretaría de Economía / INEGI. (2025, primer trimestre). Data México: Desarrolladores y Analistas de Software y Multimedia — salarios, diversidad, industrias e informalidad laboral. https://www.economia.gob.mx/datamexico/es/profile/occupation/desarrolladores-y-analistas-de-software-y-multimedia

[44] Project Management Institute. (2021). A guide to the Project Management Body of Knowledge (PMBOK® Guide) (7.ª ed.). PMI. ISBN 978-1-62825-664-2

[45] Cámara de Diputados del H. Congreso de la Unión. (2010). Ley Federal de Protección de Datos Personales en Posesión de los Particulares. Diario Oficial de la Federación.

[46] Cámara de Diputados del H. Congreso de la Unión. (1984). Ley General de Salud (Art. 100 sobre investigación en seres humanos).

[47] Secretaría de Salud. (2012). NORMA Oficial Mexicana NOM-024-SSA3-2012, Sistemas de información de registro electrónico para la salud. Intercambio de información en salud. Diario Oficial de la Federación